

**UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL
CUSCO**

**FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA,
INFORMÁTICA Y MECÁNICA**

**ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE
SISTEMAS**



TESIS DE INVESTIGACIÓN

**DESARROLLO DE UNA ARQUITECTURA DE RED NEURONAL
CONVOLUCIONAL COMO UN MODELO DEL PROCESO CEREBRAL
HUMANO PARA LA CLASIFICACIÓN DE EXPRESIONES FACIALES**

Para optar al título profesional de:
Ingeniero Informático y de Sistemas

Presentado por:
Br. Darwin Ttito Concha
Br. Paul Dany Flores Atauchi

Asesor:
Prof. Msc. Lauro Enciso Rodas

Co-Asesor:
Prof. M.Eng E. Gladys Cutipa Arapa

FINANCIADO POR EL CONSEJO DE INVESTIGACIÓN DE LA UNSAAC

CUSCO - PERÚ
2017

Dedicatoria

Dedico esta tesis a mi mamá Luz Marina, a mi tía Felicitas Magdalena y a mis hermanos Sharmely y Russel por el gran apoyo y motivación que siempre me brindan

Paul Dany Flores Atauchi

Este trabajo está dedicado a mis padres Marina y Donato, mis hermanos Edison y Sayda. A todos ellos porque día a día me aconsejan y ayudan a ser una mejor persona.

Darwin Ttito Concha

Resumen

Las expresiones faciales son un medio de comunicación no verbal que muestran las emociones de una persona, estas expresiones ayudan a transmitir información en las interacciones inter personales y facilitan el entendimiento del significado del lenguaje hablado. Por lo que se considera que poder clasificar la expresión de un rostro sería una gran fuente de información para una posterior utilización. El objetivo del presente proyecto es modelar el proceso cerebral humano para clasificar imágenes de expresiones faciales por medio de una de las técnicas de *Deep Learning*, logrando así que una máquina sea capaz de aprender de imágenes de expresiones faciales suministradas de ejemplo (datos de entrenamiento) con el objetivo de poder clasificar ejemplos futuros sin ningún tipo de intervención humana en el proceso. En la actualidad, gracias a las Redes Neuronales Convolucionales, se están logrando buenos resultados en la clasificación de imágenes, detección de objetos, comprensión de escena, en comparación con técnicas convencionales, por lo cual en este proyecto se usó la arquitectura de una Red Neuronal Convolutional para clasificar las expresiones faciales, clasificándolas en 6 categorías: enojo, miedo, alegría, tristeza, sorpresa y neutro. Este trabajo aporta a una mejor comprensión en las redes neuronales Convolucionales aplicada al reconocimiento de expresiones faciales e imágenes en general, también ayudara en el desarrollo de futuros proyectos que necesiten del reconocimiento de expresiones faciales, como: estudio de marketing, interacción hombre-máquina, psicología, análisis educativo y otros.

Palabras Claves: Expresión Facial, *Deep Learning*, Convolutional Neural Networks, Visión por Computador, Reconocimiento de Patrones, Detección de Objetos.

Abstract

Facial expressions are a means of nonverbal communication that show emotions of people, these expressions help interpersonal transmit information and facilitate the understanding of the meaning of spoken language. So that we believe that to determine the facial expression would be a rich source of information for later use. The objective of this project is to simulate the behavior our brains to recognize images of facial expressions using one of the techniques of Deep Learning, achieving a machine can learn from images of facial expressions supplied sample (training data) in order to classify future examples, without any human intervention in the process. Nowadays thanks to the technique used in this project (convolutional neural network) researchers are achieving good results in image recognition, object detection, understanding scene, compared with other conventional techniques, so in this project use the basic architecture of a convolutional neural network to recognize facial expressions, and classified into 6 categories: happiness, sadness, joy, fear, anger and surprise. This paper give us more understanding on convolutional neural network applied to the recognition of facial expressions and images in general also help in the development of future project requiring the recognition of facial expressions like systems man-machine interaction, marketing analysis based on the facial expressions of people, behavioral studies, mental health and cognitive processes.

Key Words: Facial Expression Recognition, Understanding Scene, Object Detection, Convolutional Neural Network, Deep Learning.

Índice General

Indice de Figuras	VI
Indice de Tablas	VII
I Aspectos Generales	2
1. Aspectos Generales	3
1.1. Aspectos Generales	3
1.1.1. Descripción del Problema	3
1.1.2. Identificación del Problema	4
1.2. Antecedentes	4
1.3. Objetivos	6
1.3.1. Objetivo General	6
1.3.2. Objetivos Específicos	6
1.4. Alcances	7
1.5. Justificación	7
1.6. Metodología	7
1.7. Limitaciones	8
1.8. Cronograma de Actividades	9
II Marco Teorico	10
2. Marco Teórico	11
2.1. Conceptos de Visión	11
2.1.1. Visión Humana	11
2.1.2. Visión por Computador	12
2.2. Detección de Rostros	13
2.2.1. Haar Cascade	13
2.3. Redes Neuronales	14
2.3.1. Biológicas	14
2.3.2. Artificiales	15
2.4. Arquitectura de una Red Neuronal Artificial	17
2.4.1. Capas	17

2.4.2. Funciones de Activación	18
2.4.3. Bias o Sesgo	20
2.5. Implementación de una Red Neuronal Artificial	20
2.6. Backpropagation	21
2.7. Deep Learning	22
2.8. Redes mas Comunes Consideradas dentro del Deep Learning	24
2.8.1. Autoencoder	24
2.8.2. Redes Neuronales Recurrentes	24
2.8.3. Redes Neuronales Convolucionales	25
2.9. Arquitectura de una Red Neuronal Convolutacional	25
2.9.1. Capa de Convolución	26
2.9.2. Submuestreo	28
2.9.3. Capa de normalización	29
2.9.4. Capa totalmente conectada	30
2.9.5. Función de normalización(Softmax)	30
2.10. Entrenamiento de una Red Convolutacional	31
2.11. Sobre las Expresiones Faciales	32
2.11.1. Paul Ekman	32
2.11.2. Las seis emociones básicas	32
2.11.3. Otras expresiones faciales	35
III Desarrollo del Proyecto	36
3. Desarrollo del Detector de Rostros y la Arquitectura de Red Neuronal Convolutacional	37
3.1. Detección de Rostros	37
3.2. Experimentación en la Elección de Parámetros y Capas en la Construcción de la Arquitectura CNN	39
3.3. Arquitectura Propuesta	40
3.4. DESCRIPCIÓN DE LAS CAPAS DE LA ARQUITECTURA	41
3.5. PARAMETROS DE LA ARQUITECTURA	43
3.6. ENTRENAMIENDO DE LA CNN	44
3.7. TEST AL MODELO CREADO	45
3.8. RECOPILACIÓN DE IMAGENES DE EXPRESIONES FACIALES	45
3.9. BASE DE DATOS	45
3.9.1. FER2013	45
3.10. CK+	46
3.11. FER2013 - CK+	46
3.12. RESULTADOS EXPERIMENTALES	46
3.12.1. FER2013	47
3.12.2. CK+	48
3.12.3. FER2013 - CK+	49

Resultados	52
Conclusiones	54
Recomendaciones	55
Trabajos Futuros	56
Bibliografia	56
A. OTROS CONCEPTOS	56
B. TESTING	57
C. HERRAMIENTAS	58
D. GLOSARIO	59
E. ACRONIMOS	60

Índice de Figuras

2.1.	Estructura de la percepción visual humana	12
2.2.	Esquema de las relaciones entre la visión por computadora y otras áreas afines.	13
2.3.	Detección Cascade	14
2.4.	Neurona biológica	15
2.5.	Modelo matemático de una red neuronal	17
2.6.	Capas de una red neuronal artificial.	17
2.7.	Grafica de la función Sigmoide	18
2.8.	Grafica de la función Tangencial	19
2.9.	Grafica de la función RELU	20
2.10.	Arquitectura de un RNA incluida el sesgo	20
2.11.	Descenso de gradiente.	22
2.12.	Tipos de aprendizaje.	22
2.13.	Aprendizaje supervisado.	23
2.14.	Aprendizaje no supervisado.	23
2.15.	Arquitectura de una red neuronal Auto-encoder.	24
2.16.	Arquitectura de una red neuronal Recurrente.	25
2.17.	Arquitectura de una red neuronal Convolucional.	26
2.18.	Ejemplo de convolución con un filtro de dimensiones de 2×2	27
2.19.	Ejemplo de Submuestreo con una ventana de 2×2 y calculando el promedio	29
2.20.	Capa totalmente conectada	30
2.21.	Arquitectura de una CNN con Softmax	31
2.22.	Expresión Facial de Córnea	32
2.23.	Expresión Facial de Felicidad	33
2.24.	Expresión Facial de Sorpresa	33
2.25.	Expresión Facial de Asco	34
2.26.	Expresión Facial de Tristeza	34
2.27.	Expresión Facial de Miedo	34
3.1.	Ejemplo de una imagen de entrada.	38
3.2.	Proceso de detección de rostro.	38
3.3.	Ejemplo de rostros con oclusión.	38
3.4.	Imágenes después de la primera convolución.	42
3.5.	Imágenes después del primer Pooling.	42
3.6.	Imágenes después de la segunda convolución.	42
3.7.	Imágenes después del segundo Pooling.	43

3.8. Arquitectura grafica del modelo propuesto	44
3.9. Imágenes de la base de datos FER2013	46
3.10. Imágenes de la base de datos CK+	46
3.11. Matriz de confusión, precisión del Test - FER2013	47
3.12. Precisión durante el proceso de entrenamiento y prueba (%) – FER2013	47
3.13. Perdida durante el proceso de entrenamiento y prueba (%) – FER2013	48
3.14. Matriz de confusión, precisión del Test - CK+	48
3.15. Precisión durante el proceso de entrenamiento y prueba (%) - CK+	49
3.16. Perdida durante el proceso de entrenamiento y prueba (%) – FER2013	49
3.17. Matriz de confusión, precisión del Test FER2013 - CK+	50
3.18. Precisión durante el proceso de entrenamiento y prueba (%) FER2013 - CK+	50
3.19. Perdida durante el proceso de entrenamiento y prueba (%) FER2013 - CK+	50

Índice de Tablas

1.1. Cronograma de actividades	9
3.1. Evaluación de la arquitectura 1 y sus parámetros, FER2013	39
3.2. Evaluación de la arquitectura 1 y sus parámetros, CK+	39
3.3. Evaluación de la arquitectura 2 y sus parámetros, FER2013	39
3.4. Evaluación de la arquitectura 2 y sus parámetros, CK+	40
3.5. Evaluación de la arquitectura 3 y sus parámetros, FER2013	40
3.6. Evaluación de la arquitectura 3 y sus parámetros, CK+	40
3.7. Arquitectura del modelo propuesto	41
3.8. Número de parámetros de nuestra CNN	44
3.9. Resultados obtenidos - FER2013	47
3.10. Resultados obtenidos - CK+	48
3.11. Resultados obtenidos - FER2013 - CK+	49

Introducción

Las expresiones faciales son un medio de información no verbal, útil para entender a las personas en situaciones específicas. Para un ser humano el reconocer una expresión facial es una tarea fácil, pero no lo es para un sistema automatizado basado en visión por computador. Para reconocer una expresión facial, necesitamos detectar el rostro y reconocer que expresión facial que posee. En el presente trabajo se usa el detector de rostros *Haar Cascade* para la detección y Red Neuronal Convolutacional(CNN) para el reconocimiento de la expresión facial. Se usó 3 bases de datos (FER2013 y CK+) y una tercera base de datos como resultado de la unión de las 2 bases de datos antes mencionadas.

- **Parte I:** Cubre los aspectos generales del problema, describiendo de una manera detallada el problema al cual se quiere dar solución, los trabajos relacionados, los objetivos a alcanzar, la metodología y las limitaciones encontradas en el desarrollo de la investigación.
- **Parte II:** Proporciona los fundamentos teóricos necesarios que son vitales para el desarrollo y entendimiento del proyecto.
- **Parte III:** Desarrolla y muestra los experimentos realizados con diferentes configuraciones sobre una arquitectura de Red Neuronal Convolutacional(CNN). Se describe a detalles el funcionamiento de los métodos elegidos para la detección y el reconocimiento de expresiones faciales. Los resultados obtenidos son interpretados en términos de una métrica de error y precisión, y se proponen trabajos futuros.

Parte I

Aspectos Generales

Capítulo 1

Aspectos Generales

1.1. Aspectos Generales

1.1.1. Descripción del Problema

Uno de los sentidos más importantes de los seres humanos es la visión. Ésta es empleada para obtener la información visual del entorno físico. Según Aristóteles, “Visión es saber que hay y donde mediante la vista”. De hecho, se calcula que más del 75 % de las tareas del cerebro son empleadas en el análisis de la información visual. El refrán popular de “Una imagen vale más que mil palabras” tiene mucho que ver con los aspectos cognitivos de la especie humana. Casi todas las disciplinas científicas emplean utilajes gráficos para transmitir conocimiento¹.

Uno de los más grandes concursos a nivel mundial en clasificación de imágenes reporta que las técnicas tradicionales (como las técnicas de extracción de características en imágenes estáticas: *Principal component analysis* (PCA), *Edges detector*, *Gabor wavelet*; Video: PCA, *Discrete cosine transform* (DCT), *optical flow* e *image difference*) están siendo superadas por técnicas de *Deep Learning* basadas en el proceso cerebral humano. Dicho éxito se debe a que las técnicas tradicionales requieren de un ambiente controlado y no son tolerables a cambios como: traslación, rotación y escalado, por otro lado las técnicas de *Deep Learning* demuestran ser mas robustas y efectivas frente a estos tipos de cambios².

Diversas actividades cotidianas necesitan del reconocimiento de imágenes, tal es el caso del reconocimiento de expresiones faciales, que en los últimos años se ha convertido en una de las tareas más estudiadas por investigadores en todo el mundo, con el fin de alcanzar un margen de error mínimo para posteriormente centrarse en el desarrollo de aplicaciones en distintos campos, como: estudio de marketing, interacción hombre-máquina, psicología y análisis educativo ³, las cuales han sido abordada por diferentes técnicas tradicionales no obteniendo los resultados prometedores en imágenes reales que contienen distintos tipos de variaciones (mencionados en el parrafo anterior) limitando así la implementación y desarrollo de aplicaciones útiles para el bien común (aplicaciones antes mencionadas).

¹Visión Humana, fuente: Sistemas Adaptativos y Bioinspirados en Inteligencia Artificial(S.A.B.I.A.)

²*Deep Learning vs. Machine Learning* fuente: Analytics Vidhya

³Las expresiones faciales de las emociones, historia y aplicaciones, fuente: Ciencia Cognitiva

1.1.2. Identificación del Problema

Las técnicas tradicionales para el reconocimiento de expresiones faciales usadas en la actualidad necesitan de un ambiente controlado (iluminación constante, alta calidad de imagen, poco ruido, imagen sin ocultación), y no son tolerables a cambios como rotación, traslación, escalado, limitando así la creación de aplicaciones con imágenes del mundo real (imágenes obtenidas a partir de cámaras de seguridad). Por lo que hay la necesidad de usar nuevas técnicas del estado del arte que nos permitan obtener mejores resultados superando así la limitación antes mencionada.

1.2. Antecedentes

Se muestra una lista de trabajos resaltantes que hacen uso de técnicas de *Deep Learning*, los cuales sirvieron de inspiración y fuente de información valiosa en el desarrollo de este trabajo. También se presentan trabajos dedicados al reconocimiento de expresiones faciales utilizando técnicas tradicionales de visión por computador y *machine learning*.

“Gradient-Based Learning Applied to Document Recognition” [?]

Descripción:

- Este proyecto muestra uno de los inicios en lo que respecta al aprendizaje profundo con Redes Neuronales Convolucionales
- Este proyecto utiliza la data set MNIST, la función de activación no lineal tanh(x) y el promedio aritmético para la parte del Submuestreo y obtuvo un 99.3
- Este proyecto utiliza un paradigma de aprendizaje denominada “Redes transformadoras de gráfico”, tal sistema permite entrenar varios módulos basado en el gradiente, con el fin de minimizar la medida del rendimiento global.

Objetivo: Reconocer documentos manuscritos

Conclusión: La utilización de Gradient Based learning permitió alcanzar altos niveles de precisión en el reconocimiento de documentos manuscritos, dando más relevancia al Deep Learning.

“Traffic Sign Recognition with Multi-Scale Convolutional Networks” [?]

Descripción:

- Este trabajo se hizo como parte de la competencia GTSRB.
- En este trabajo se aplican Redes Neuronales Convolucionales en la tarea de clasificación de señales de tráfico, estas Redes Neuronales Convolucionales aprenden características en todos los niveles de su arquitectura.

- Este trabajo produjo una precisión de 98.31 % durante la competición estando por debajo con 0.53 % de diferencia respecto al rendimiento humano que es del 98.81 %.

Objetivo: Reconocer señales de transito

Conclusión: Las Redes Convolucionales Multi - Escalas son mejores en el reconocimiento de señales de transito a comparación con la mayoría de técnicas tradicionales

“Multi-column Deep Neural Networks for Image Classification” [?]

Descripción:

- Este paper menciona que los métodos tradicionales de visión por ordenador y Machine Learning no podían igualar el rendimiento humano en tareas tales como el reconocimiento de dígitos escritos a mano o señales de tráfico.
- Este paper menciona que se crean varias columnas neuronales profundas, que se convierten en expertos en áreas específicas de las entradas pre-procesadas. Este método es el primero en lograr un rendimiento casi humano.
- Este paper menciona que se crean varias columnas neuronales profundas, que se convierten en expertos en áreas específicas de las entradas pre-procesadas. Este método es el primero en lograr un rendimiento casi humano.
- En este proyecto logra una precisión del 99.46 % en el reconocimiento de señales de tráfico superando a su predecesor por un 0.24 % y logrando un rendimiento superior al humano por 0.62 %.

Objetivo: Evaluar el rendimiento de las Redes Neuronales Profundas Multi-Columnas en la clasificación de imágenes.

Conclusión: Las Redes Convolucionales Multi - Escalas son mejores en el reconocimiento de señales de transito a comparación con la mayoría de técnicas tradicionales.

“ImageNet Clasificación with Deep Convolutional Neuronal Networks” [?]

Descripción:

- En este proyecto se unen ImageNet, que es una data set compuesto de más de 100.000 categorías con cerca de 1.2TB de imágenes, desarrollada por el laboratorio de visión de la Universidad de Stanford.
- Este proyecto crea un modelo basado en los trabajos desarrollados hasta ese momento referente a Redes Neuronales Convolucionales logrando bajar el error de $\pm 25\%$ a $\pm 15\%$. Su modelo consistía en 650K neuronas, 832M de sinapsis y 60M de parámetros. El entrenamiento de su modelo se realizó con 2 GPU's durante el tiempo de 1 semana.

Objetivo: Clasificación de imágenes de la base de datos ImageNet en más de 1000 categorías, utilizando Redes Neuronales Convolucionales.

Conclusión: Las Redes Neuronales Convolucionales logran alto nivel de precisión gracias a la gran cantidad de datos en la fase de entrenamiento y a la utilización de GPU's

"Teaching Deep Convolutional Neural Network to Play Go" [?]

Descripción:

- Este trabajo logra desarrollar una Red Neuronal Convolucional, que es capaz de lograr precisión de predicción de una posición de una pieza de 41.1 % y 44.4 % en los diferentes conjuntos de datos de Go superando anteriores técnicas del estado del arte en esta tarea por márgenes significativos.

Objetivo: Crear un programa capaz de jugar a Go mediante Deep Learning.

Conclusión: Las Redes Neuronales Convolucionales no solo sirven para la visión por computador, sino también son muy útiles para la teoría de juegos.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar una arquitectura de Red Neuronal Convolucional que sea capaz de obtener niveles de precision confiables (con un minimo margen de error) en el reconocimiento de expresiones faciales, permitiendo asi contribuir en el desarrollo de futuras aplicaciones del mundo real que sirvan para el beneficio de la sociedad.

1.3.2. Objetivos Específicos

- Selección de las bases de datos de expresiones faciales y transformación de datos a un formato estandar para su posterior utilizacion.
- Investigar los filtros de convolucion para la correcta seleccion de los parametros.
- Investigar la funcion de submuestreo para la correcta selección de los parametros.
- Investigar las funciones de activación y funciones de normalizacion para la correcta selección de los parametros.
- Diseñar la arquitectura propuesta(configuracion de parametros, numero de capas y funciones de activacion y normalizacion), basandonos en los objetivos previos.
- Entrenar la arquitectura propuesta.
- Evaluar el modelo creado a partir de la arquitectura propuesta.
- Analizar e interpretar los resultados

1.4. Alcances

En este trabajo de investigacion se lograron los siguientes alcances.

- Se propuso una nueva arquitectura para el reconocimiento de expresiones faciales, basada en las Redes Neuronal Convolucional, capaz de obtener altos niveles de precision que seran de utilidad para el desarrollo de futuras aplicaciones del mundo real.
- Se creo una nueva base de datos, la cual fue resultado de la union de las dos bases de datos antes mencionadas(FER2013 y CK+).
- Contribuimos con la comunidad academica del país y la region brindandoles informacion de un tema de investigación actual que servira como base para el desarrollo de futuras aplicaciones y trabajos relacionados.

1.5. Justificación

En la actualidad se ha dado más realce a algunas disciplinas de la inteligencia artificial como: *Machine Learning* y *Deep Learning*, disciplinas que brindan distintas técnicas que están dando solución a problemas de clasificación de imágenes, comprensión de escena, análisis de sentimientos y otros. Así es el caso de la visión artificial donde las Redes Neuronales Convolucionales está proporcionando mejores resultados en comparación con algoritmos y técnicas tradicionales.

En este trabajo, presentamos un estudio resumido de la investigación hecha en *Deep Learning* que servirá tanto para los investigadores como para los lectores. También este trabajo ayudara para el desarrollo de futuros proyectos de clasificación de imágenes en distintos campos (seguridad, medicina y biología, internet y la nube, entretenimiento, maquinas autónomas y otros)⁴.

1.6. Metodología

Dada la naturaleza del trabajo de investigación, se utilizó los métodos de investigación bibliográfica, explorativa y aplicativa. Bibliográfica ya que se recogió y analizo información para obtener conocimientos previos sobre *Deep Learning* y el detector *Haar Cascade*. Explorativa porque se seleccionó información relevante procedente de la etapa de investigación bibliográfica, para la construcción de la arquitectura de una Red Neuronal Convolucional basándonos en trabajos previos relacionados con la línea de investigación. Aplicativa por que se utilizaron los conocimientos adquiridos [?][?].

⁴Aplicaciones de Deep Learning, fuente: NVIDIA GPUs - el motor del aprendizaje profundo(deep learning)

1.7. Limitaciones

- Difícil acceso a herramientas tecnológicas de hardware, principalmente GPU's de alta capacidad, necesarias para la fase de entrenamiento de la Red Neuronal Convolutacional. Por consiguiente, la solución es alquilar servidores en la nube especializados en el entrenamiento de arquitecturas de *Deep Learning*.
- Carencia de organizaciones peruanas que brinden bases de datos para poder utilizarlos en la fase de entrenamiento ya que se requiere miles de imágenes (imágenes de acuerdo al proyecto de investigación en el que se trabaje, como: rostros, danzas, señas, sitios arqueológicos y entre otros) para que se cree un modelo eficiente y robusto, llevando a utilizar base de datos de organizaciones extranjeras que fomentan la investigación en esta área.

1.8. Cronograma de Actividades

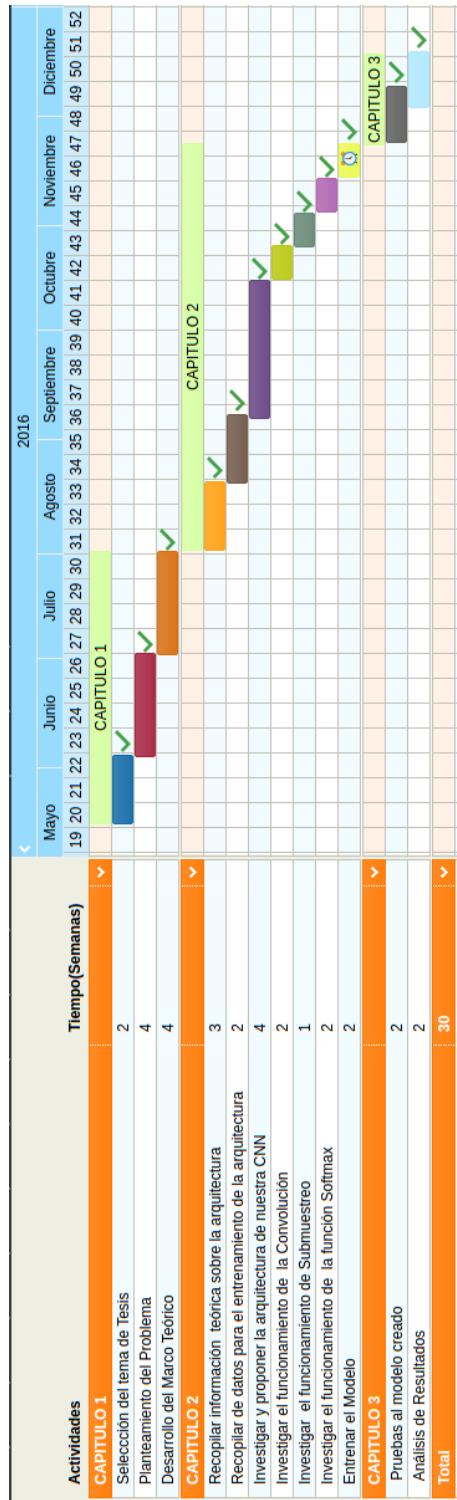


Tabla 1.1: Cronograma de actividades

Parte II

Marco Teorico

Capítulo 2

Marco Teórico

2.1. Conceptos de Visión

2.1.1. Visión Humana

De una manera muy general, visión se entiende como toda acción de ver, sin embargo, desde un punto de vista más técnico, visión es la capacidad de interpretar nuestro entorno gracias a los rayos de luz que alcanzan el ojo. Otros autores definen visión como una capacidad necesaria más no imprescindible para realizar las actividades cotidianas.

Desde el punto de vista de la medicina, la visión humana o sentido de la vista se reduce a un órgano receptor conocido como el *ojo*, la membrana y retina son los encargados de recibir las impresiones luminosas para luego transmitirlas al cerebro por medio de las vías ópticas (ver figura 2.1). En adición, el ojo es un órgano situado en la cavidad orbitaria, esta protegida por los párpados y por la secreción de las glandulas lagrimales. Los ojos son sensibles a ondas de radiación electromagnética de longitudes específicas. Estas ondas se registran como la sensación de la luz. Cuando la luz penetra en el ojo, pasa a través de la córnea, la pupila y el cristalino, y llega por último a la retina, donde la energía electromagnética de la luz se convierte en impulsos nerviosos que pueden ser utilizados por el cerebro. Los impulsos abandonan el ojo a través del nervio óptico. La región más sensible del ojo en la visión normal diurna es una pequeña depresión de la retina llamada fóvea en el cual se enfoca la luz que viene del centro del campo visual (por campo visual entendemos aquello a lo que mira el sujeto). Puesto que la lente simple convexa invierte la imagen, el campo visual derecho es representado a la izquierda de la retina y el campo inferior representado en lo alto de la retina. El ojo es un sistema óptico muy imperfecto. Las ondas de luz no solo tienen que pasar a través de los humores y el cristalino, después penetrar la red de los vasos sanguíneos y fibras nerviosas antes de que lleguen las células sensibles los bastones y los conos de la retina donde la luz se convierte en impulsos nerviosos. A pesar de estas imperfecciones el ojo funciona muy bien. La fóvea es capaz de percibir un cable telefónico a 400 m de distancia. En buenas condiciones el ojo puede percibir un alambre cuyo grosor no cubre más de 0,5 mm.

También existen otras definiciones que indican que, el ojo es la puerta de entrada por la que ingresan los estímulos luminosos que se transforman en impulsos eléctricos gracias a unas células especializadas de la retina que son los conos y los bastones. Entonces, el nervio óptico

transmite los impulsos eléctricos generados en la retina al cerebro, donde son procesados en la corteza visual. Finalmente, en el cerebro tiene lugar el complicado proceso de la percepción visual gracias al cual somos capaces de percibir la forma de los objetos, identificar distancias, detectar los colores y el movimiento [?].

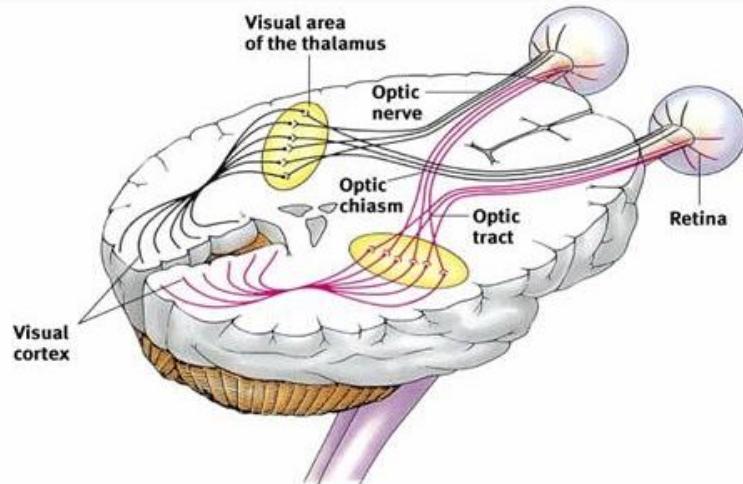


Figura 2.1: Estructura de la percepción visual humana.

Fuente: Fernando Vila Arroyo, “El Libro Blanco de la Iluminación”. España 2013.

2.1.2. Visión por Computador

La visión artificial o también conocida como visión por computador es una disciplina científica que incluye métodos para adquirir, procesar, analizar y comprender las imágenes del mundo real con el fin de producir información numérica o simbólica para que puedan ser tratados por un computador. Tal y como los humanos usamos nuestros ojos y cerebros para comprender el mundo que nos rodea, la visión por computador trata de producir el mismo efecto para que las computadoras puedan percibir y comprender una imagen o secuencia de imágenes y actuar según convenga en una determinada situación. Esta comprensión se consigue gracias a distintos campos como la geometría, la estadística, la física y otras disciplinas. La adquisición de los datos se consigue por varios medios como secuencias de imágenes, vistas desde varias cámaras de video o datos multidimensionales desde un escáner médico.

Hay muchas tecnologías que utilizan la visión por computador (figura 2.2), entre las cuales tenemos: reconocimiento de objetos, detección de eventos, reconstrucción de una escena (*mapping*) y restauración de imágenes [?].

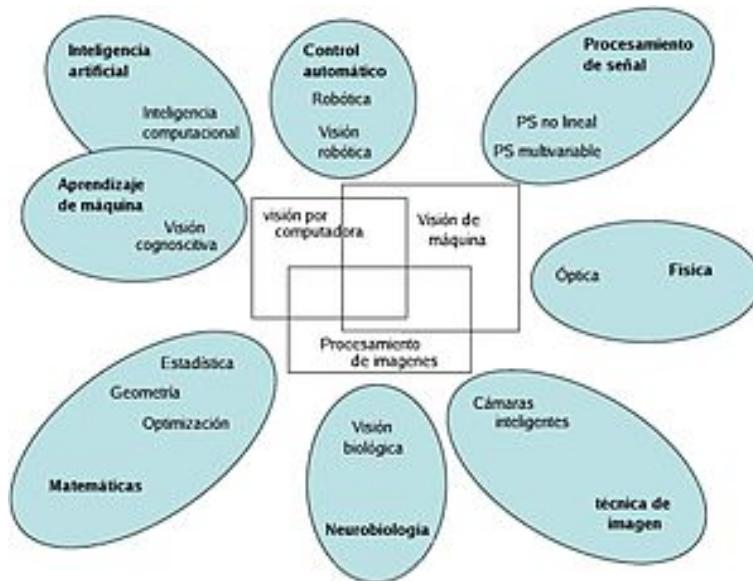


Figura 2.2: Esquema de las relaciones entre la visión por computadora y otras áreas afines.

Fuente: *Visión artificial, Wikipedia*.

2.2. Detección de Rostros

En los últimos años investigadores de todo el mundo vienen trabajando en la detección y reconocimiento de rostros, esto, debido a la gran cantidad de aplicaciones que este brinda, aplicaciones relacionadas con la seguridad pública, estudios de marketing y psicología de las personas. El rostro es una de las partes del cuerpo que más rasgos representativos muestra en una persona, por lo cual es de suma importancia poder identificar, reconocer y clasificar cada una de estas características, de ahí su gran importancia para el desarrollo de las aplicaciones antes mencionadas. En la localización o detección de rostros, la primera etapa de los sistemas automatizados basados en visión por computador es encontrar el área que envuelve el rostro dentro de la imagen de entrada. La ubicación exacta de la cara es todavía una tarea difícil. Dentro de los muchos trabajos orientados a resolver este problema, Viola-Jones ha sido ampliamente utilizada debido a su robustez para la localización de objetos. La segunda etapa relacionada con el reconocimiento o clasificación de rostros es otra tarea muy estudiada. En general para realizar esta tarea son utilizados algoritmos de clasificación de imágenes que están disponibles en muchas bibliotecas *open source*, tales como OpenCV [?].

2.2.1. Haar Cascade

Haar Cascade es un efectivo método para la detección de objetos, basado en la utilización de características de tipo *Haar* este método resulta muy eficiente y robusto para este tipo de tareas. Fue propuesto por Paul Viola y Michael Jones, de ahí el sobrenombre Viola-Jones. Debido a que este método sirve para la detección de objetos, investigadores vieron por conveniente aprovechar sus grandes cualidades para la detección de rostros, alcanzando

asi altos niveles de precisión en esta tarea. Existen muchas librerías *open source* que disponibilizan modulos con la implementación de este algoritmo, una de esas tantas es la popular librería *Open Computer Vision Library* mas conocida como OpenCV, el *framework* general de detectores de objetos se ha popularizado y ha motivado a la comunidad a generar sus propios clasificadores de objetos. Estos clasificadores usan características parecidas a las del tipo *Haar* que se aplican sobre la imagen. [?].

Haar Cascade de una manera resumida, es un enfoque basado en *machine learning*, donde, una función *cascade* es entrenada con muchas imágenes positivas(imágenes de caras) y negativas(imágenes que no sean caras). Entonces, se extraen las características de ellas, entrenando un modelo capaz de reconocer rostros con dichas características.

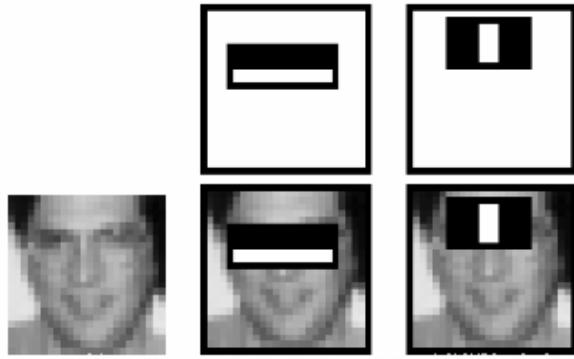


Figura 2.3: Detección Cascade.

Fuente: *Evaluation of Haar Cascade Classifiers for Face Detection, OpenCV*.

2.3. Redes Neuronales

2.3.1. Biológicas

Son el principal elemento del Sistema Nervioso. Las redes neuronales biológicas son el resultado de la unión de varias neuronas entrelazadas entre sí. Una neurona es una célula compuesta por tres partes fundamentales: el cuerpo, un número de extensiones llamadas dendritas que sirven de entradas, y una larga extensión llamada axón, la cual se activa como salida. Existe un proceso de comunicación entre neuronas, el cual es conocido como 'la sinapsis', este proceso conecta el axón de una neurona a las dendritas de las otras neuronas para comunicarse por medio de impulsos eléctricos. Las neuronas están dispuestas en múltiples capas. Por lo general las neuronas de una primera capa reciben entradas desde otra capa y envían sus salidas o impulsos nerviosos a las neuronas de una tercera. Existe un proceso de retroalimentación que se origina cuando los impulsos nerviosos de una neuronal son enviados a ella misma, originando así un ciclo donde la información se mantiene por períodos de tiempo. Similar, puede ocurrir la comunicación entre neuronas de la misma capa.

Las conexiones entre neuronas tienen pesos asociados que representan la influencia de una sobre la otra. Si dos neuronas no están conectadas, el correspondiente peso de enlace es cero. Esencialmente, cada una envía su información de estado multiplicado por el correspondiente

peso a todas las neuronas conectadas con ella. Luego cada una, a su vez, suma los valores recibidos desde sus dendritas para actualizar sus estados respectivos.

Las redes biológicas son entrenadas por medio de la experiencia vivida durante el día a día (imágenes recolectadas por el ojo humana y procesadas por el cerebro), de esta forma, estimulando a cada neurona a aprender características especiales que ayuden a identificar un determinado objeto. Cabe mencionar que la efectividad y precisión con la que se pueda reconocer un objeto, depende mucho de la cantidad de imágenes previas que se hayan visto sobre este. Además, se producirán respuestas cuando, en la utilización, se presenten entradas totalmente nuevas para el sistema. De este modo el sistema de red neuronal no reside necesariamente en la elegancia de la solución particular sino en su generalidad de hallar solución a problemas particulares, habiéndose proporcionado ejemplos del comportamiento deseado. Esto permite la evolución de los sistemas autómatas sin una reprogramación explícita [?].

De acuerdo con estudios previos, muchos trabajos orientados al estudio del cerebro humano y la medicina, mencionan que una persona tiene alrededor de 10^{11} neuronas, cada una con alrededor de 10^4 salidas. Donde, la estructura de neuronas de la corteza cerebral es modular: si bien todas las partes del cerebro son relativamente similares, diferentes partes hacen diferentes cosas; a partir de una estructura general, según la experiencia se generan nuevas estructuras específicas al problema a resolver [?].

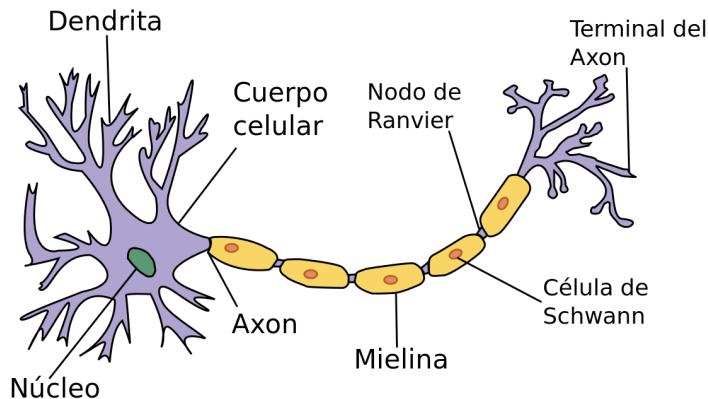


Figura 2.4: Neurona biológica

Fuente: Patri Tezanos, Neurociencia, 2016.

2.3.2. Artificiales

Las Redes Neuronales Artificiales (ANN) imitan el funcionamiento del cerebro, básicamente, el tipo de conexiones existentes (ejemplo: las neuronas de una capa previa están conectadas a neuronas de la siguiente capa), estructura (número de capas) y transferencia de información entre neuronas. Este tipo de arquitectura son aptas para resolver problemas que no poseen un algoritmo claramente definido, transformando así una entrada en una salida; aprenden, reconocen y aplican relaciones entre objetos. Para realizar este tipo de procesos o tareas, se emplea normalmente un conjunto de ejemplos representativos para 'entrenar' el sistema o la red neuronal (en nuestro caso, imágenes de expresiones faciales), que, a su vez,

se adaptan ajustando los pesos de cada neurona de tal manera que pueda producir salidas deseadas a cada imagen de entrada.

Además, similar a las redes neuronales biológicas, se producirán respuestas, cuando en la utilización se presenten entradas totalmente desconocidas por el sistema entrenado. De este modo el sistema de red neuronal artificial no se limita a solo reconocer imágenes que hayan sido previamente vistas, sino en su generalidad para hallar similitudes entre la imagen de entrada y las imágenes previas antes de la fase de entrenamiento, generando así un sistema robusto capaz de obtener una semejanza enorme a las redes neuronales biológicas.

Las Redes Neuronales Artificiales se basan en el circuito de procesamiento de entradas en el cual los pesos son sumados. Las funciones de peso son conocidas generalmente como atenuadores. En la implementación, las entradas a una neurona son pesadas multiplicando el valor de la entrada por un factor que es menor o igual a uno. El valor de los factores de peso es determinado por el algoritmo de aprendizaje. Las entradas atenuadas son sumadas usando una función no lineal llamada 'Sísmoide'. Si la salida de la función suma excede el valor de entrada máximo de la neurona, esta responde generando una salida. Cada neurona tiene varias entradas y su salida está conectada a un conjunto de otros procesadores de entradas.

Cuando una red funciona en modo normal, a partir de los datos presentados en la entrada, se genera un patrón específico de salida. La relación entre la entrada y la salida será determinada durante la etapa de entrenamiento, entonces cuando una entrada conocida es presentada será dada una salida efectiva. Durante esta etapa de entrenamiento, el algoritmo de aprendizaje ajusta los pesos de las entradas hasta que se alcanza la salida esperada, esto se logra por medio de la minimización de una función de costo (ver ecuación 2.1), la cual es representada como la diferencia entre la salida esperada y la salida obtenida.

Devido a la compleja conexión que se realiza entre capas de la red, la complejidad con respecto a términos computacionales y tiempo de ejecución, puede crecer de manera exponencial. Esto se debe a que cada neurona está conectada a cientos de neuronas de la siguiente capa y cada neurona de esa siguiente capa realiza lo mismo. Por lo tanto mientras más sea el número de capas y neuronas, aparentemente, el sistema será mejor, pero también será más complejo y difícil de entrenar. [?].

La figura 2.5 muestra las partes de una neurona artificial, la cual es similar a la estructura de una neurona biológica.

$$Y_i = f(\sum W_{i,j}X_j - \theta_i) \quad (2.1)$$

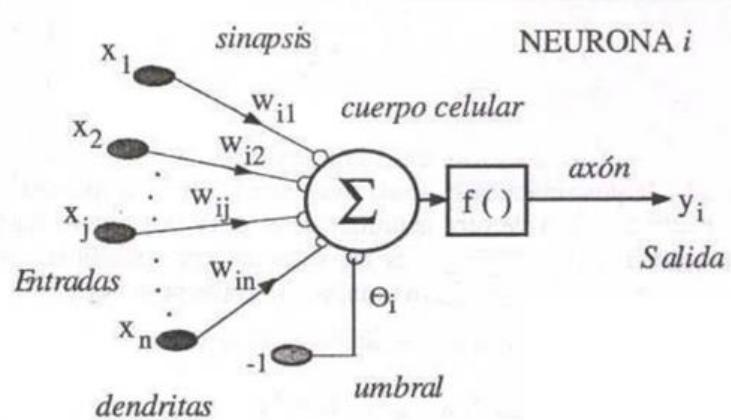


Figura 2.5: Modelo matemático de una red neuronal

Fuente: Yuly Cristina Moreira Monserrate, Inteligencia Artificial, 2015.

2.4. Arquitectura de una Red Neuronal Artificial

2.4.1. Capas

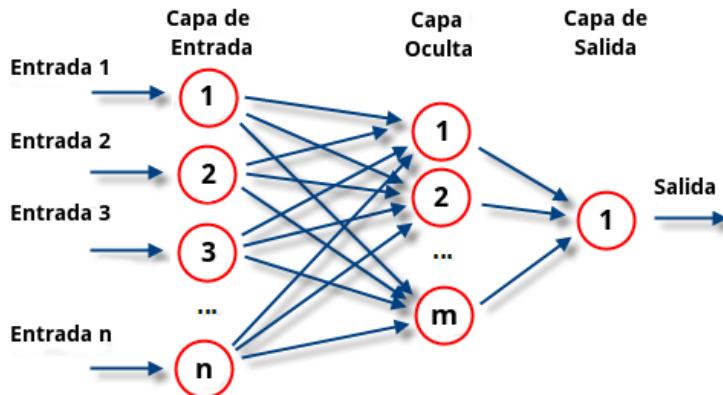


Figura 2.6: Capas de una red neuronal artificial.

Fuente: Perceptrón multicapa, Wikipedia.

Una red neuronal artificial está compuesta por tres capas:

- **Capa de Entrada.-** Es la encargada de recepcionar los datos de entrada que posteriormente serán procesados. La representación de estas entradas puede variar dependiendo del tipo de problema que se quiera resolver. En el caso de imágenes, esta se puede representar como una matriz que contiene un determinado valor representativo para cada pixel.
- **Capa Oculta.-** Es la encargada de realizar el procesamiento pesado de la información, para posteriormente enviar la información ya procesada a la capa de salida. información a la capa de salida.

- **Capa de Salida.-** Contiene los resultados como una lista de números. Donde el numero de neuronas de la capa de salida tiene que ser igual al numero de posibles salidad que ofresca el problema a resolver. Otorgando un valor a cada neurona y finalmente, por medio de una funcion de normalizacion obtener la salida definitiva, que corresponde a una sola neurona.

2.4.2. Funciones de Activación

La función de activación es la encargada de mantener los números producidos por cada neurona dentro de una rango razonable(generalmente números reales entre 0 y 1). Esta funcion recibe como entrada la suma de todos los números que llegan por medio de las conexiones entrantes, transforma el valor mediante una determinada funcion y produce un nuevo valor que sera utilizado para la siguiente iteracion. Existen distintas funciones de activacion estudiadas y experimentadas en trabajos previos, donde, algunas de ellas muestran mayor desempeño que las otras.

- **Función de activación Sigmoide**

Muchos procesos naturales y curvas de aprendizaje de sistemas complejos muestran una progresión temporal desde unos niveles bajos al inicio, hasta acercarse a un clímax transcurrido un cierto tiempo; la transición se produce en una región caracterizada por una fuerte aceleración intermedia. La función Sigmoide permite describir esta evolución. Su gráfica tiene una típica forma de "S"(ver figura 2.7), y esta limitada en el rango de 0 a 1 en el eje de las ordenadas. A menudo la función Sigmoide se refiere al caso particular de la función logística y que viene definida por la ecuación 2.2 [?].

$$f(x) = \frac{1}{1 + \exp^{-x}} \quad (2.2)$$

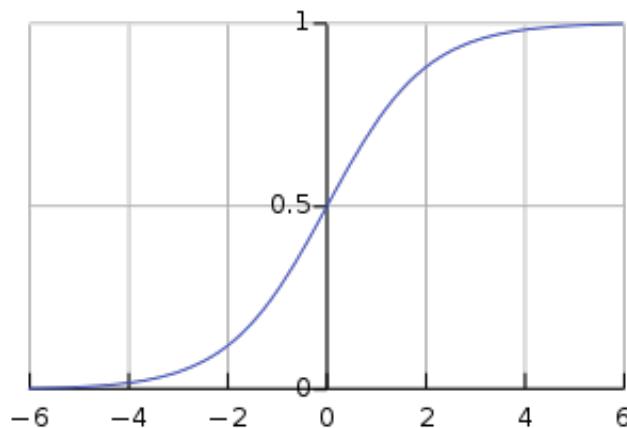


Figura 2.7: Grafica de la función Sigmoide

Fuente: *Sigmoid Function, Wikipedia*.

■ Función de activación Tangencial

Es la versión continua de la función signo y se usa en problemas de aproximación. Es importante por sus propiedades analíticas. Es continua a valores en el intervalo [-1,1] (ver figura 2.8) e infinitamente diferenciable, Esta función está definida esta definida por la ecuacion 2.3 [?].

$$\tanh(x) = \frac{\exp^x - \exp^{-x}}{\exp^x + \exp^{-x}} \quad (2.3)$$

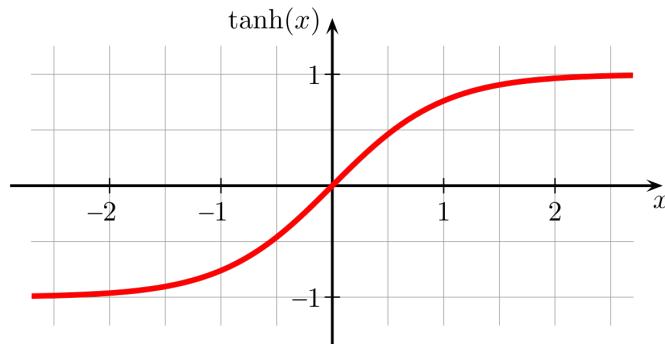


Figura 2.8: Grafica de la función Tangencial

Fuente: *Tangente hiperbólica, Wikipedia.*

■ Función de activación RELU (*Rectified Linear Unit*)

Se conoce como una función de rampa y es análoga a la rectificación de onda media. Esta función de activación fue introducida por primera vez a una red dinámica, en un artículo del año 2000, con fuertes motivaciones biológicas y justificaciones matemáticas. Finalmente en el año 2015, despues de ser usada dentro de las redes neuroanles convolucionales, alcanza un gran nivel de eficacia y robustes, superando ampliamente a las funciones de activación logística Sigmoide (la cual esta inspirada en la teoría de probabilidades) y tangente hiperbólica. Siendo asi la mas popular para las Redes Neuronales Profundas. Esta funcion es representada por medio de la ecuación 2.4, y debido a esa ecuación, la parte negativa en el eje abscisas se mantiene en cero, generando la grafica como se muestra en la figura 2.9 [?].

$$f(x) = \text{Max}(0, x) \quad (2.4)$$

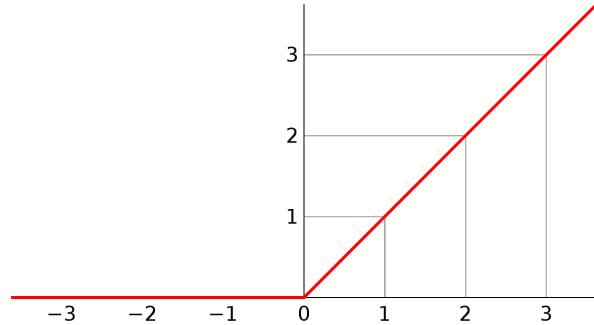


Figura 2.9: Grafica de la función RELU

Fuente: *Hyperbolic tangent and ReLU neurons, Int8.*

2.4.3. Bias o Sesgo

Es una cantidad constante que cada neurona de alguna capa oculta añade justo antes de aplicar la función de activación, este valor puede incrementar o disminuir a la suma de productos (sumatoria de los productos obtenidos después de multiplicar el valor de cada neurona con su respectivo peso que conecta hacia la siguiente neurona). El objetivo de este valor constante es lograr una convergencia más rápida de la red y evitar que el valor final entrante a una neurona sea un valor muy despreciable o muy significativo. La figura 2.10 muestra como este valor es integrado en la arquitectura de una red neuronal.

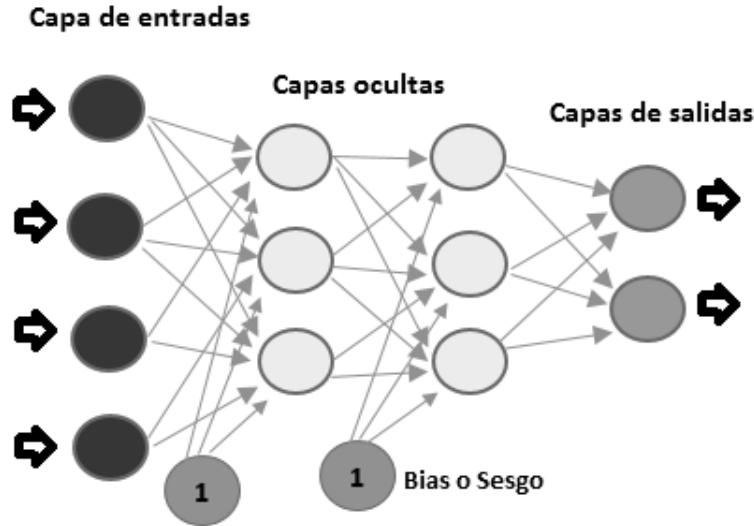


Figura 2.10: Arquitectura de un RNA incluida el sesgo

Fuente: Propio

2.5. Implementación de una Red Neuronal Artificial

Una forma sencilla de implementar redes neuronales, consiste en almacenar los pesos en matrices. Se considera que la red neuronal es un grafo y simplemente representamos este

grafo por medio de su matriz de adjacencia, donde cada posicion (i, j) almacena el peso entre la neurona i y la neurona j . Posteriormente guardamos los valores de todas las neuronas de una determinada capa en un vector, el producto del vector y la matriz de pesos de salida nos da los valores de entrada de cada neurona en la siguiente capa. Después se aplica la función de activación a cada elemento de ese segundo vector, y repetimos el proceso [?].

La implementación antes mencionada es una idea general de como se podria implementar una red neuronal(no es el unico algoritmo). En la vida real existen distintos tipos de redes neuronales, donde cada una de ellas presenta una implementación diferente, siendo algunas de ellas mas eficientes computacionalmente que otras.

2.6. Backpropagation

El *BackPropagation* es un algoritmo de aprendizaje supervisado que se usa para entrenar redes neuronales artificial, dicho algoritmo se basa en el descenso de gradiente que es un algoritmo de optimización utilizado para determinar los valores de los parámetros (coeficientes) de una función f que minimiza una función de costes. El descenso de gradiente se utiliza mejor cuando los parámetros no pueden ser calculados analíticamente (por ejemplo, usando algebra lineal) y deben ser buscados por un algoritmo de optimización [?].

La figura 2.11 muestra la representación de como el descenso de gradiente trabaja en la búsqueda de los mejores parametros para una determinada función (ejemplo: sea la función $f(x) = ax + b$, donde los parametros son las constantes a y b). El objetivo es alcanzar el círculo central, el cual representa los parametros óptimos buscados. Para alcanzar dicho objetivo se realiza una serie de paso (representados por las rectas trazadas entre cada par de puntos rojos, como se muestra en la figura 2.11) que sirven para ajustar los parametros de tal forma que poco a poco se acerquen a la función objetivo.

El algoritmo de *Backpropagation* es muy intuitivo. Dada una entrada a la red, esta genera una salida, la cual posteriormente es comparada con la salida deseada, consiguiendo así el primer error de salida (función de costo o diferencia entre la salida deseada y la salida obtenida por la red). Seguido, este error es propagado hacia atrás, distribuyendo una porción de dicho error a todas las neuronas de la capa anterior que aportaron para la obtención de la salida alcanzada. Este proceso se repite, capa por capa, hasta que todas las neuronas de la red hayan recibido una porción del error obtenido. El objetivo de realizar estos pasos, es crear una red cuyos pesos de cada neurona minimicen la función de costo, consiguiendo así un nivel de precisión inversamente proporcional al error alcanzado por cada entrada(mientras menos error, mayor será la precisión alcanzada).

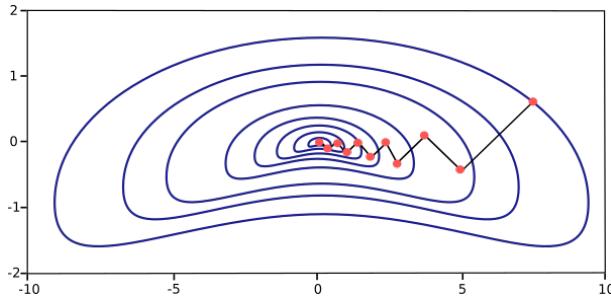


Figura 2.11: Descenso de gradiente.

Fuente: *5 algorithms to train a neural network, Neural Designer*.

2.7. Deep Learning

El *Deep Learning* es un concepto muy amplio, lo que implica que este tenga muchas definiciones. Sin embargo, de una forma muy general, se puede decir que el *Deep Learning* es un concepto que surge de la idea de imitar el cerebro humano por medio de una abstracción mas profunda de las redes neuronales, con el objetivo de crear una inteligencia que mas se asemeje a la inteligencia humana, esta enfoque utiliza una capacidad de abstracción jerárquica, es decir, una representación de los datos de entrada en varios 'niveles'. A diferencia de las Redes Neuronales tradicionales, el *Deep Learning* utiliza multiples capas ocultas para la selección de características que son útiles para un mejor aprendizaje; de esta manera, la capa mas profunda dentro de las capas ocultas, obtendrán la representación de características con mayor nivel de abstracción(reconocimiento de lineas, puntos, curvas y otros).

Este enfoque no es mas que un conjunto de algoritmos de *Machine Learning*, que intenta detectar abstracciones de un alto nivel en datos, haciendo uso de arquitecturas compuestas de transformaciones no-lineares multiples [?]. Existen varios tipos de aprendizajes, las cuales son tomadas como base para el entrenamiento de una red neuronal en general. Sin embargo, dos principales categorías son resaltadas por las arquitecturas profundas (como se muestra en la figura 2.12):

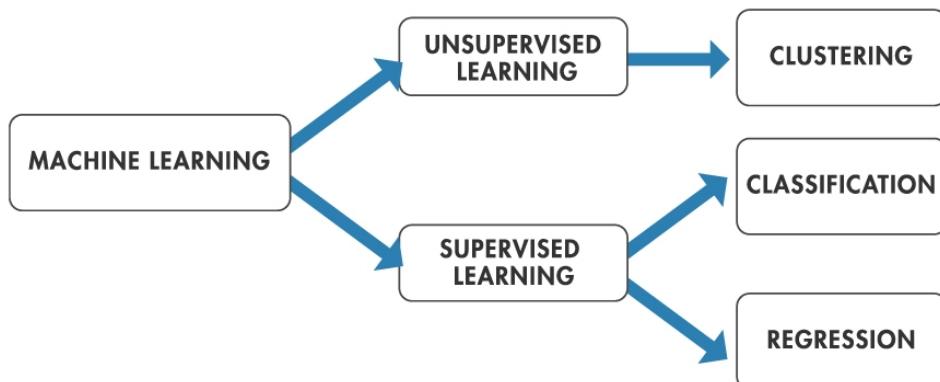


Figura 2.12: Tipos de aprendizaje.

Fuente: *Big Data with MATLAB, Math Works*.

- **Supervisado:** Se caracteriza porque su entrenamiento es controlado por un agente externo. Es decir, este agente externo guia el entrenamiento de la red mediante una comparación entre la salida esperada y la salida obtenida por medio de la red. En otras palabras, para realizar este proceso, la base de datos a entrenar necesita contener un campo que indique la salida que se espera por cada dato de entrada. Por ejemplo, sea una arquitectura dedicada a la reconocimiento y clasificación de números en imágenes, entonces, cada vez que pasemos una imagen como entrada a la red, esta imagen deberá ir acompañada de una etiqueta que indique cuál es el número que se está pasando [?].

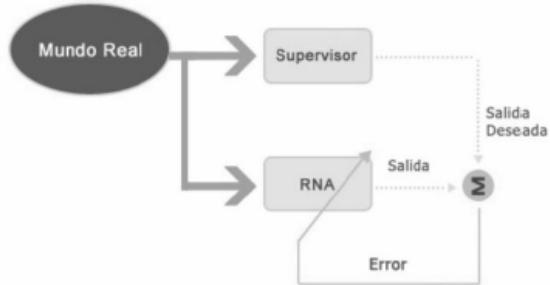


Figura 2.13: Aprendizaje supervisado.

Fuente: López S, Jesús A. Caicedo B, Eduardo F.

- **No supervisado:** Este enfoque sugiere que el aprendizaje sea realizado presentándole a la red los datos directamente, es decir, ahora no existe un agente externo, campo o etiqueta que indique a la red cuáles son los datos que se le proporciona como entrada. La red aprende de ellos, agrupándolos de acuerdo a la similaridad de sus características, en algunos casos se realiza este tipo de agrupación de forma probabilística [?].



Figura 2.14: Aprendizaje no supervisado.

Fuente: López S, Jesús A. Caicedo B, Eduardo F.

- **Híbrido:** Algunas redes tienden a utilizar ambos tipos de aprendizaje para su fase de entrenamiento, ya sea comenzando por un pre-entrenamiento supervisado y finalizando con uno no supervisado o viceversa. Este enfoque se sigue con el objetivo de lograr un mejor ajuste, disminuyendo el tiempo de convergencia y entre otras funcionalidades [?].

2.8. Redes mas Comunes Consideradas dentro del Deep Learning

2.8.1. Autoencoder

Es un tipo de Red Neuronal Artificial utilizada para el aprendizaje no supervisado de codificaciones eficientes. El objetivo de una autoencoder es aprender una representación (codificación) para un conjunto de datos, típicamente con el propósito de reducción de dimensionalidad. Recientemente, el concepto autoencoder se ha vuelto más ampliamente utilizado para el aprendizaje de modelos generativos de datos [?].

Un auto-codificador, o autoencoder, aprende a producir a la salida exactamente la misma información que recibe a la entrada. Por eso, las capas de entrada y salida siempre deben tener el mismo número de neuronas. Por ejemplo, como se muestra en la figura 2.15, si la capa de entrada recibe los píxeles de una imagen, se espera que la red aprenda a producir en su capa de salida exactamente la misma imagen que ha sido introducido [?].

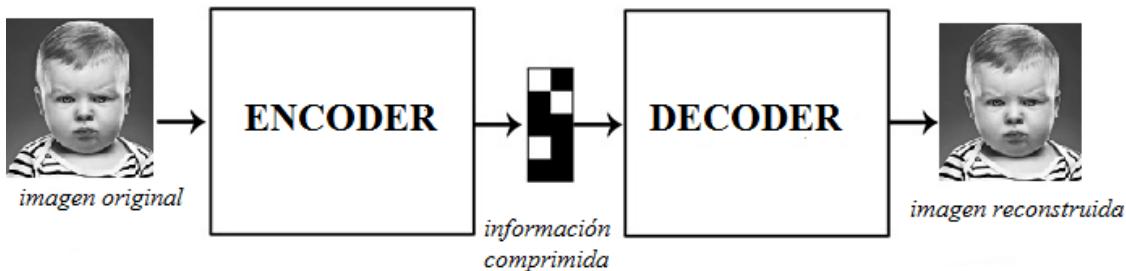


Figura 2.15: Arquitectura de una red neuronal Auto-encoder.

Fuente: Propio.

2.8.2. Redes Neuronales Recurrentes

Las Redes de Neuronas Recurrentes (*Recurrent Neural Networks*) no tienen una estructura de capas definida, sino que permiten conexiones arbitrarias entre todas las neuronas, incluso creando ciclos. Esto permite incorporar a la red el concepto de temporalidad, y permite que la red tenga memoria, porque los números que introducimos en un momento dado en las neuronas de entrada son transformados, y continúan circulando por la red incluso después de cambiar los números de entrada por otros diferentes [?].

Este tipo de redes, debido a la capacidad de retener información por cortos períodos de tiempo, es altamente utilizado en trabajos relacionados con el procesamiento y análisis de videos, donde las entradas a la red son un conjunto de frames(imágenes), siendo cada imagen la continuación de la anterior. Sin embargo, similar a las otras redes neuronales, la complejidad en términos de tiempo de ejecución(entrenamiento de la red) sigue siendo una limitación para experimentar con dichos trabajos, ya que el número de parámetros a optimizar siguen siendo miles de miles, debido a las múltiples conexiones que se presentan entre neuronas.

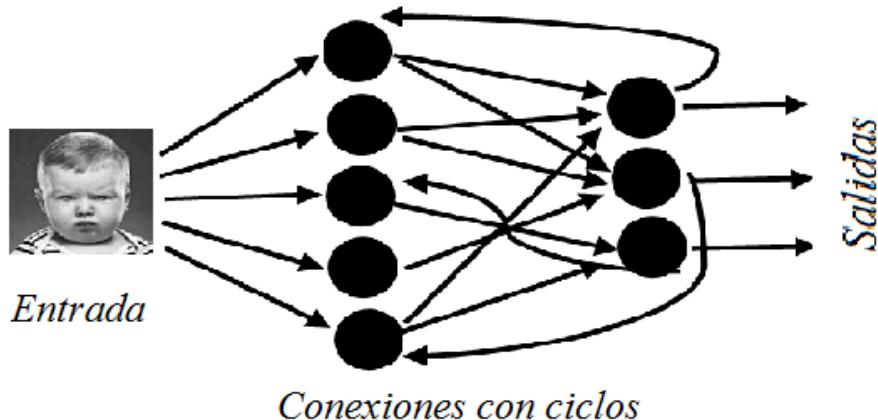


Figura 2.16: Arquitectura de una red neuronal Recurrente.

Fuente: Propio.

2.8.3. Redes Neuronales Convolucionales

Las Redes Neuronales Convolucionales (*Convolution Neural Network*) a diferencia de las Redes Neuronales Recurrentes, mantienen el concepto de capas, pero cada neurona de una capa no recibe conexiones entrantes de todas las neuronas de la capa anterior, sino sólo de algunas. Esto favorece que una neurona se especialice en una región de la lista de números de la capa anterior, y reduce drásticamente el número de pesos y de multiplicaciones necesarias. Lo habitual es que dos neuronas consecutivas de una capa intermedia se especialicen en regiones solapadas de la capa anterior [?].

Muy diferente del esquema tradicional de las Redes Neuronales Artificiales, estas redes presentan una gran variedad de tipos de capas, donde cada una de ellas tiene una función específica y esta puede repetirse mas de una vez. La siguiente sección sera dedicada a describir con mayor detalles la arquitectura modelo de una Red Neuronal Convolutacional.

2.9. Arquitectura de una Red Neuronal Convolucional

Las Redes Neuronales Convolucionales son una estructura compuesta de varias fases entrenables, aprendiendo de cada una de las características con diferentes grados de abstracción. La entrada y salida de cada una de estas etapas son conjunto de arreglos llamados mapas de características, a la salida cada mapa de características representa una característica particular extraída de la imagen de entrada. Cada fase generalmente está compuesta por tres capas: Convolucion, función no lineal y una capa de sub-muestreo. Las ultimas capas por lo general son un conjunto de capas totalmente conectadas.

Una típica arquitectura de Red Neuronal Convolutacional para clasificación supervisada está basada en varias etapas (los tres tipos de capas mencionadas en el parrafo anterior: Convolucion y sub-muestreo) seguidas de un clasificador (el conjunto de capas totalmente conectadas). Una de las primeras arquitecturas, es la red propuesta por Yann LeCun (figura 2.17). Esta red fue utilizada para resolver el problema de reconocimiento de caracteres manuscritos,

utilizando una arquitectura con dos fases.

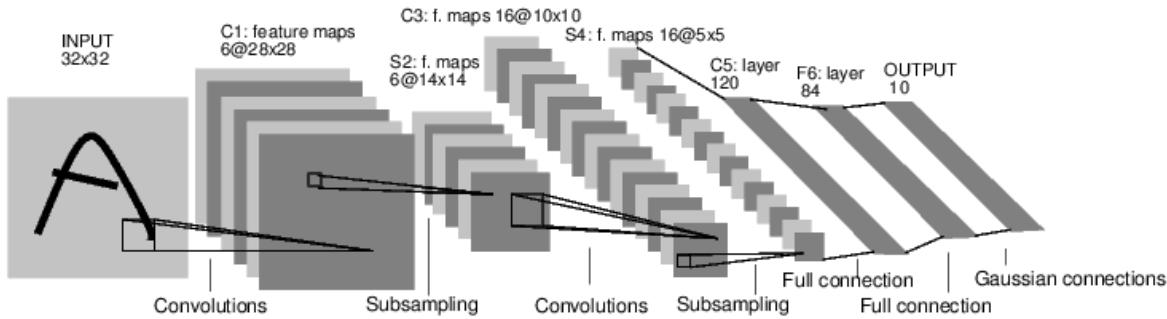


Figura 2.17: Arquitectura de una red neuronal Convolucional.

Fuente: Source: Yann LeCun, 1998.

Esta red denominada Let-Net, toma una imagen como entrada, la capa siguiente esta constituido por un conjunto de filtros de convolución (mapas de características), seguida por una capa de sub-muestreo encargada de la reducción de dimensionalidad, seleccionando así solo los datos mas relevantes. La capa de convolución esta compuesta por seis mapas de características, donde cada uno de ellos no es mas que una matriz con valores asociados. A continuación, se encuentra la capa de sub-muestreo, que, como se menciono antes, agrupa las salidas de las nuevas imágenes originadas por la capa de convolución, generando así la misma imagen pero con dimensiones menores e información mas relevante. Este nuevo mapa de características sirve de entrada para la siguiente fase dedicada a encontrar características de mayor abstracción. Una cosa importante que cabe resaltar, es que, a medida que se avanza en las fases se aprenden características mas relevantes, pero mas invariantes a posición (por el sub-muestreo). Finalmente, las capas totalmente conectadas se encargan de evaluar las posibles combinaciones de las características aprendidas para lograr clasificar las imágenes dadas [?].

2.9.1. Capa de Convolución

La capa de convolución es el bloque de construcción básico de una red, esta capa hace la mayor parte del trabajo pesado computacional, debido a que se realizan multiplicaciones de matrices entre la imagen y los filtros de convolución.

- **Visión general e intuición sin cerebro.** Los parametros de la capa de convolución consisten en un conjunto de filtros que durante la fase de entrenamiento son aprendidos. Cada filtro es pequeño espacialmente (a lo largo de la anchura y altura), este filtro es aplicado a través de toda la imagen de entrada. Por ejemplo, un filtro típico en una primera capa de una Red Neuronal Convolutinal podría tener un tamaño de 5x5x3 (es decir, 5 píxeles anchura y la altura, y 3 ya que las imágenes tienen profundidad 3, los canales de color). Durante el la operacion de convolucion entre el filtro y la imagen de entrada, este se desliza a través del ancho y la altura del volumen de entrada y calcula el productos escalares entre estos dos elementos. A medida que se desplaza el filtro sobre

la anchura y la altura del volumen de entrada se produce un mapa de activación de 2 dimensiones que da las respuestas de ese filtro en cada posición espacial. Intuitivamente, la red aprenderá filtros que se activan cuando ven algún tipo de función visual, como un borde en una determinada orientación o una mancha de un cierto color. Después se tendrá todo un conjunto de filtros en cada capa de convolución, y cada uno de ellos va a producir un mapa de activación de 2 dimensiones por separado. Finalmente se apilan estos mapas de activación a lo largo de la dimensión de la profundidad y producen el volumen de salida. [?].

- **La vista del cerebro.** Cada entrada en el volumen de salida 3D también se puede interpretar como una salida de una neurona que mira sólo una pequeña región en los parámetros de entrada y comparte con todas las neuronas de la izquierda y derecha (ya que todos estos números resultaría de aplicar el mismo filtro). [?].
- **Conectividad local.** Cuando se trata de entradas de alta dimensión como las imágenes, como se vio anteriormente, no es práctico conectar neuronas a todas las neuronas en la capa anterior. En su lugar, se va a conectar cada neurona a sólo una región local del volumen de entrada. La extensión espacial de esta conectividad es un hiperparámetro llamado campo receptivo de la neurona (equivalente al tamaño del filtro). La extensión de la conectividad a lo largo del eje de profundidad es siempre igual a la profundidad del volumen de entrada. Es importante destacar nuevamente esta simetría en cómo tratamos las dimensiones espaciales (anchura y altura) y la dimensión de la profundidad: Las conexiones son locales en el espacio (a lo largo del ancho y la altura), pero siempre llenas a lo largo de toda la profundidad del volumen de entrada [?].

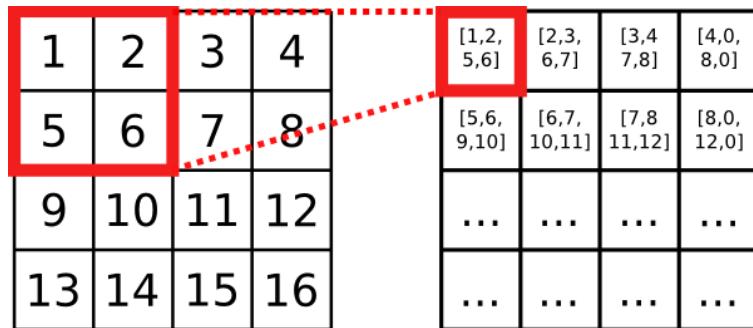


Figura 2.18: Ejemplo de convolución con un filtro de dimensiones de 2×2 .

Fuente: *Que es y como funciona Deep Learning*, Rubén López.

- **Pseudo – Código.** La representación de la convolución por medio de una fórmula matemática se muestra en la ecuación 2.5. Los valores de un píxel en la imagen de salida se calculan multiplicando cada valor del kernel por los valores de píxeles de la imagen de entrada correspondientes. Esto se puede describir algorítmicamente con el siguiente pseudo-código:

$$V = \frac{\sum_{i=0}^{q^1} \sum_{j=0}^{q^2} f_{i,j} * k_{i,j}}{F} \quad (2.5)$$

Algorithm 1 Pseudo-Codigo Convolucion

La convolucion de una image $f(x,y)$ con un kernel $k(x,y)$ con dimensiones $h \times w$ y $(2h+1) \times (2w+1)$ respectivamente produce una nueva imagen $g(x,y)$

```
procedure CONVOLUCION( $f, k$ )           ▷ Convolucion de la imagen f con el kernel k
    for  $y := 1$  to  $W$  do
        for  $x := 1$  to  $H$  do
             $sum = 0$ 
            for  $i := -h$  to  $h$  do
                for  $j := -w$  to  $w$  do
                     $sum = sum + k(j, i) * f(x - j, y - i)$ 
             $g(x, y) = sum$ 
    return  $g$                                 ▷ Resultado de la convolucion entre f y k
```

Donde:

- $f_{i,j}$: Corresponde al pixel en la posición i, j de la imagen f respecto al kernel k .
- $k_{i,j}$: Corresponde al pixel en la posición i, j del kernel k .
- $q1 \times q2 = (2h + 1) \times (2w + 1)$: Representa las dimensiones del kernel.
- F : Es la suma de los coeficientes del kernel (1 si la suma es igual a 0).
- $g(i, j)$: Representa el valor de salida del pixel en la posición i, j .

first revision and fix of the theoretical framework

2.9.2. Submuestreo

La arquitectura tradicional de una red neuronal convolucional sugiere que se inserte una capa de sub-muestreo despues de cada capa de convolucion. Su función es reducir progresivamente el tamaño espacial de la imagen de entrada con el objetivo de reducir la cantidad de parámetros a ser calculados en la red, y por lo tanto, también para controlar el sobre ajuste. La capa de agrupación funciona independientemente en cada segmento de profundidad de la entrada y la redimensiona espacialmente, dependiendo de las dimensiones de la ventana de sub-muestre. Existen diferentes funciones de agrupación para realizar este tipo de operacion, funciones como: MAX, MIN, MODA, MEDIANA, etc, cada una de estas funciones se desenvuelve de manera muy diferente, dependiendo del problema que ese pretende resolver. La forma más común es una capa de agrupación con filtros de tamaño 2x2 y función de agrupación MAX, aplicando un salto de dos pixeles hacia abajo y hacia arriba para realizar el desplazamiento e iterar la operacion de sub-muestreo sobre toda la imagen, de esta forma descartando el 75 % de las activaciones. En este caso, cada operación MAX tomaría un máximo de 4 números (pequeña región de dimensiones de 2x2). La dimensión de profundidad no cambia. Más generalmente, la capa de agrupación tiene estas principales características:

- Acepta un volumen de tamaño $W1 \times H1 \times D1$
- Requiere 2 hiperparámetro

- Su extensión espacial F
 - El desplazamiento S
- Produce un volumen de tamaño: $W2 \times H2 \times D2$, donde :
- $W2 = \frac{W1-F}{S+1}$
 - $H2 = \frac{H1-F}{S+1}$
 - $D2 = D1$
- Introduce parámetros cero, ya que calcula una función fija de la entrada.
 - Tener en cuenta que no es común utilizar cero como relleno(*padding*) para agrupar capas.

En la práctica solo fueron encontradas dos variaciones comunes de la capa de sub-muestreo con función de agrupación MAX: Una capa de agrupación con $F = 3$, $S = 2F$, $S = 2$ (también llamada superposición de agrupación) y más comúnmente $F = 2$, $S = 2F$, $S = 2$. Los tamaños de agrupación con campos receptivos más grandes son demasiado destructivos [?].

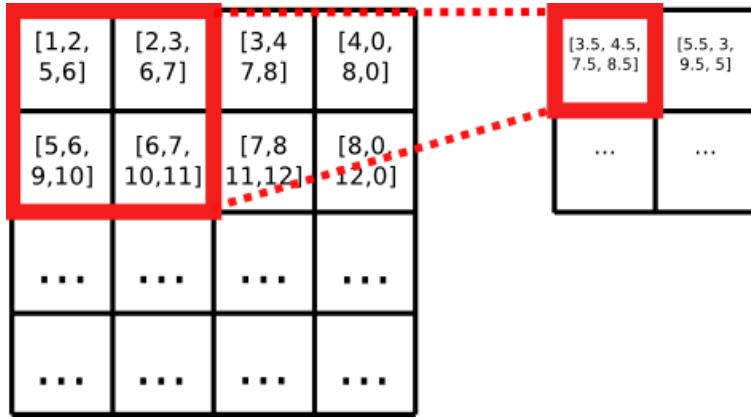


Figura 2.19: Ejemplo de Submuestreo con una ventana de 2X2 y calculando el promedio

Fuente: Que es y como funciona Deep Learning, Rubén López.

2.9.3. Capa de normalización

Existen muchos tipos de capas de normalización propuestas hasta la actualidad, algunos de ellos fueron creados con la intención de asemejar más la red, al comportamiento real del cerebro. Sin embargo, estas capas a pesar de aparentar ser un gran aporte para conseguir una inteligencia artificial pura, han caído debido a que en la práctica su aporte es casi nula.

El objetivo de una capa de normalización es, como su mismo nombre lo dice, normalizar las activaciones de la capa anterior, es decir, se aplica una transformación que mantiene la activación de cierre media en 0 y la desviación estándar cerca de 1 [?].

2.9.4. Capa totalmente conectada

Las neuronas en una capa completamente conectada tienen conexiones completas con todas las activaciones(neuronas) en la capa anterior, haciendo de este tipo de capas un grafo muy denso o grafo completo(figura 2.20), el cual computacionalmente es muy costoso, sin embargo, generalmente dentro de las redes neuronales convolucionales, a lo mucho son usadas 2 a 3 capas totalmente conectadas, haciendo de este un trabajo ligeramente mas facil de computar. Este tipo de capas son como las que se ven en las redes neuronales regulares. Por tanto, sus activaciones pueden calcularse con una multiplicación matricial. [?].

Esta capa basicamente toma un volumen como entrada y su salida es un vector de N dimensiones, donde N es el número de clases correspondientes al problema que se esta resolviendo(en el caso de clasificación). Por ejemplo, si se esta trabajando en una red, la cual sera capaz de reconocer dígitos a partir de imágenes como entrada, entonces, el número de salidas sera 10(una salida para cada números del 0 a 9). Cada número en este vector de N dimensiones representa la probabilidad que este tiene para pertenecer a una determinada clase(esta probabilidad es obtenida gracias a la función de normalización, la cual se describe en la sub-sección 2.9.5), donde la suma de todas las probabilidades es 1. Sea el problema antes planteado, si el vector resultante es $[0, 0, 1, 0, 0, 5, 0, 0, 5, 0, 0, 0, 0, 0, 0, 0, 8]$, la probabilidad de que la imagen sea un 1 es de 10 %, mientras que la probabilidad de que sea un 9 es de 80 %.

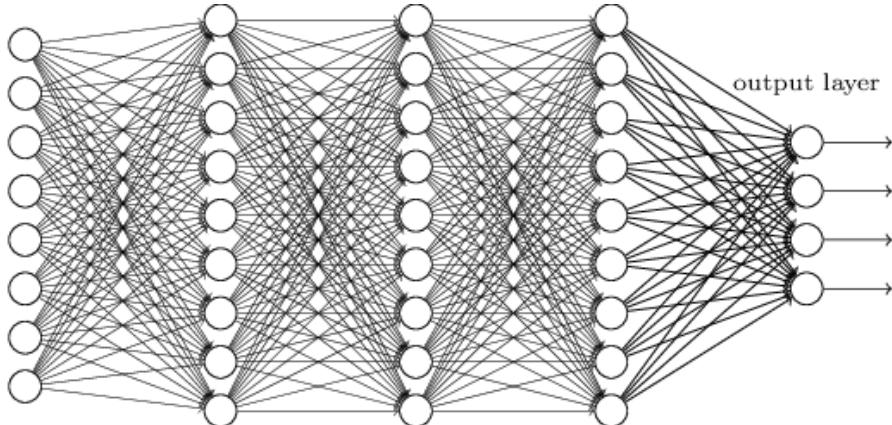


Figura 2.20: Capa totalmente conectada

Fuente: Michael A. Nielsen, <http://neuralnetworksanddeeplearning.com/chap6.html>

2.9.5. Función de normalización(Softmax)

La función de normalización softmax, tambien conocida como función exponencial normalizada, no es mas que nombre para la regresión lineal multinomial o simplemente clase múltiple de regresión logística. En su esencia, regresión de softmax es una generalización de la regresión logística que podemos utilizar para la clasificación de clase múltiple (bajo el supuesto de que las clases son mutuamente excluyentes). En cambio, utilizamos el modelo de regresión logística (estándar) en tareas de clasificación binario.

Esta función tiene como entrada el vector de N dimensiones obtenida por la capa total-

mente conectada, y como salida, un vector de probabilidades. La figura 2.21 muestra como esta función se integra en la red.

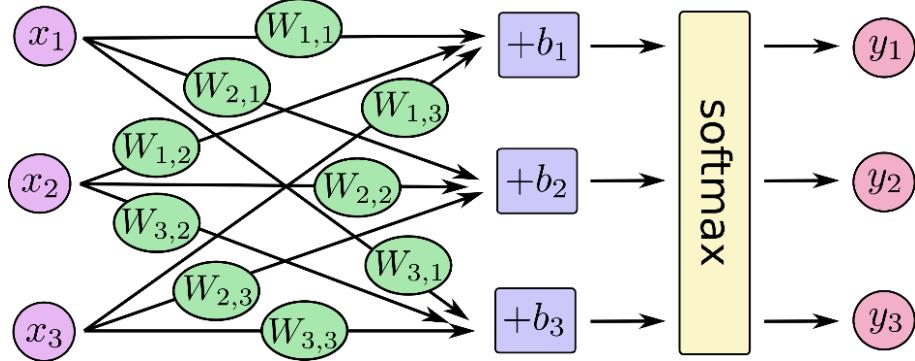


Figura 2.21: Arquitectura de una CNN con Softmax

Fuente: Samuel Salvatella, <http://ssalva.bitballoon.com/blog/2016-08-30-tensorflow/>

En su representación matemática, como se mencionó antes, esta función es una generalización de la función logística que permite la utilización de un vector de dimensión. La función está dada por la ecuación 2.6.

$$P(Y = j | Z^i) = \phi_{\text{softmax}}(Z^i) = \frac{\exp^{Z^i}}{\sum_{j=0}^k \exp^{Z_k^i}} \quad (2.6)$$

Donde:

$$Z = w_0 x_0 + w_1 x_1 + \dots + w_m x_m = \sum_{l=0}^m w_l x_l = w^T x$$

2.10. Entrenamiento de una Red Convolutacional

El proceso de entrenamiento en una red neuronal convolucional, se basa en el algoritmo *BackPropagation* (como se describió en la subsection 2.6), el cual consiste en calcular una función objetivo que minimiza el error, por medio de la retro propagación de este, hacia las capas anteriores, de tal manera que los pesos de las conexiones entre neuronas son ajustadas.

El algoritmo *BackPropagation*, como se describió anteriormente, es muy intuitivo. Este sigue la siguiente secuencia de pasos:

- Primero, se proporciona datos de entrada a la red.
- Segundo, son propagadas dichas entradas hasta la capa de salida, con pesos iniciales definidos o aleatorios.
- Tercero, se calcula el error en la capa de salida.
- Cuarto, se propaga dicho error hacia las neuronas ocultas (hacia atrás).
- Quinto, se cambia los pesos de las conexiones.

2.11. Sobre las Expresiones Faciales

2.11.1. Paul Ekman

Después de que su madre desarrolló una enfermedad mental y se suicidó, Paul Ekman (psicólogo y científico del comportamiento) dedicó su vida a la Psicoterapia y ayudar a las personas con trastornos mentales. Él comenzó su investigación en la comunicación no verbal en la década de 1950, el desarrollo de maneras sistemáticas para medir el lenguaje corporal. En el proceso, descubrió que, a través de la investigación empírica, pudo identificar constantemente las expresiones faciales creadas por el movimiento de los músculos de la cara. Y así, Ekman amplió su investigación para incluir expresiones faciales y sus significados [?].

2.11.2. Las seis emociones básicas

Antes de Ekman llegó a la escena, se creía ampliamente (por antropólogos incluyendo Margaret Mead) que las expresiones faciales y las emociones que ellos representan se determinaron por la cultura – que las personas aprendieron a hacer y leer las expresiones faciales de sus sociedades. Ekman se dispuso a probar esta idea en 1968. Él viajó a Papúa Nueva Guinea para estudiar las expresiones faciales de los miembros de la tribu Fore apartada, donde aprendió que podían identificar constantemente las emociones en las expresiones faciales por mirar fotos de la gente de otras culturas, a pesar de que la tribu no había sido expuesta a cualquier exterior culturas.

Se hizo evidente, entonces, que las expresiones faciales son interculturales, su investigación reveló que existe un conjunto universal de ciertas expresiones faciales se utilizan tanto en el mundo occidental y oriental. Esta lista de expresiones faciales universales, que Ekman publicó en el año 1972, dispone de las seis emociones básicas. Tomar por lo vistazo a la lista, así como imágenes, definiciones y movimientos musculares de estas emociones, a continuación:

- **Cólera:**

- **Descripción.-** El antagonismo hacia una persona o un objeto a menudo se sentía después de que usted siente que ha sido agraviado u ofendido.
- **Movimientos musculares faciales.-** La reducción de las cejas, apretar y estrechar los labios, los ojos mirando, apretando los párpados inferiores, con menos frecuencia, empujando la mandíbula hacia adelante.



Figura 2.22: Expresión Facial de Cólera

Fuente: *Las 6 emociones básicas*, Paul Ekman

■ Felicidad:

- **Descripción.-** Agradable sensación de satisfacción y bienestar.
- **Movimientos musculares faciales.-** Smiling – tirando hacia arriba comisuras de la boca, contrayendo los músculos grandes orbitales alrededor de los ojos.



Figura 2.23: Expresión Facial de Felicidad

Fuente: *Las 6 emociones básicas*, Paul Ekman

■ Sorpresa:

- **Descripción.-** Sensación de malestar o sorpresa ante un hecho inesperado.
- **Movimientos musculares faciales.-** Levantando las cejas altas (que puede causar arrugas en la frente), abriendo los ojos como platos, dejando caer la mandíbula tan boca es ágape.



Figura 2.24: Expresión Facial de Sorpresa

Fuente: *Las 6 emociones básicas*, Paul Ekman

■ Asco:

- **Descripción.-** Desagrado intenso o condena causada por algo ofensivo o repulsivo.
- **Movimientos musculares faciales.-** La reducción de las cejas, curvando el labio superior, arrugando la nariz.



Figura 2.25: Expresión Facial de Asco

Fuente: *Las 6 emociones básicas*, Paul Ekman

■ Tristeza:

- **Descripción.-** Sentimiento de infelicidad o tristeza.
- **Movimientos musculares faciales.-** Los párpados caídos, la reducción de las esquinas de la boca, labios fruncidos, los ojos bajos.



Figura 2.26: Expresión Facial de Tristeza

Fuente: *Las 6 emociones básicas*, Paul Ekman

■ Miedo:

- **Descripción.-** Sensación de aprehensión provocada por la percepción de peligro, amenaza o imposición de dolor.
- **Movimientos musculares faciales.-** Levantando las cejas / dibujar las cejas juntas, tensando los párpados inferiores, que se extiende horizontalmente labios, la boca ligeramente abierta.



Figura 2.27: Expresión Facial de Miedo

Fuente: *Las 6 emociones básicas*, Paul Ekman

2.11.3. Otras expresiones faciales

Los hallazgos de Ekman sobre las expresiones faciales universales revelaron el carácter intercultural de la relación entre la comunicación no verbal y la emoción, sin embargo, las teorías de Ekman han evolucionado desde que ideó su lista de emociones básicas. En la década de 1990, añadió una serie de otros a la lista de emociones universales, aunque hizo hincapié en que no todos ellos pueden ser identificados utilizando expresiones faciales. Estas emociones adicionales son [?]

- Diversión
- Desprecio
- Contentamiento
- Vergüenza
- Emoción
- Culpa
- El orgullo de los logros
- Alivio
- Satisfacción
- Placer sensorial
- Vergüenza
- Neutro

Parte III

Desarrollo del Proyecto

Capítulo 3

Desarrollo del Detector de Rostros y la Arquitectura de Red Neuronal Convolucional

3.1. Detección de Rostros

En este trabajo se optó por utilizar como etapa inicial dentro de la fase de consultas a la red, la construcción de un detector de rostros, debido a que, al momento de desarrollar una aplicación orientada a las necesidades del mundo real, este no solo recibira como entrada imágenes que contengan exactamente el rostro de la persona, sino, imágenes con el cuerpo completo o algunas partes adicionales aparte del rostro. Sin embargo, en objetivo del trabajo es poder detectar la expresión facial de una persona, para lo cual, basta con tener como entrada a la red una imagen que delimite el rostro de la persona. De ahí, la necesidad de utilizar un algoritmo de detección de rostros para la extracción de la región de interes que posteriormente servira como entrada para la red neuronal convolucional encargada de reconocer la expresión facial correspondiente. La figura 3.1 muestra un ejemplo de una imagen de entrada, en la cual, se puede observar detalles adicionales aparte del rostro(el sombrero y el fondo), los cuales no aportan carasteristicas relevantes que ayuden al reconocimiento de la expresion facial.

Para esta etapa se utilizó el detector de objetos *Haar Cascade*, un algoritmo muy utilizado, cuya implementación puede ser encontrado en distintas librerías orientadas al procesamiento de imágenes, tales como OpenCV⁵. Como se describió en la sección 2.2.1, este algoritmo utiliza técnicas de *machine learning*. Su proceso de entrenamiento se realiza con imágenes positivas y negativas(imágenes que representan y no representan rostros), creando así un modelo capaz de detectar rostros, basandose en la detección de características *Haar*. La entrada para esta etapa es una imagen cualquiera, el proceso consiste en detectar el rostro en dicha imagen(en caso exista algun rostro) y extraerlo en otra imagen en escala de grises, la cual tendra un tamaño aproximado de 48x48 pixeles(dependiendo de las dimensiones del rostro). Esta última

⁵OpenCV es una librería *open source* que contiene algoritmos relacionados con el área de visión por computador, <http://opencv.org/>

imagen será la entrada para el modelo en la fase de consultas. Nótese que para la detección de un rostro y la asignación de su respectiva expresión facial, no es necesario mantener la imagen a coloros, puesto que este no es una característica necesaria para conseguir el objetivo. La figura 3.2 muestra los pasos a seguir para la detección y extracción del rostro en una imagen.



Figura 3.1: Ejemplo de una imagen de entrada.

Fuente: Consuelo Ferrús, <http://www.acompasando.org/orar-el-asombro/>

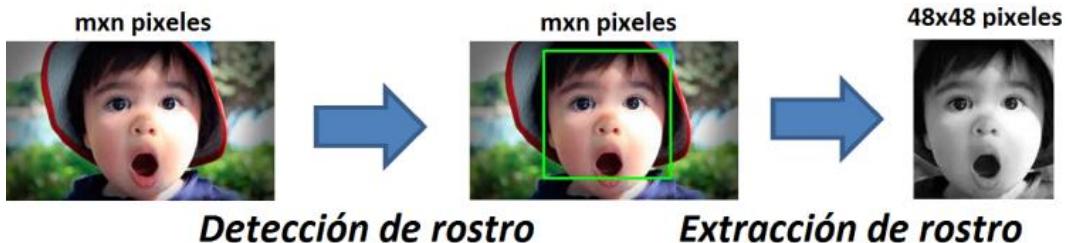


Figura 3.2: Proceso de detección de rostro.

Fuente: Propio

Se optó por la utilización del detector de rostros *Haar Cascade*, debido a que este es ampliamente utilizado por el nivel de precisión que posee [?]. Sin embargo, esta técnica aun presenta algunas fallas cuando el rostro presenta algún tipo de oclusión (figura 3.3). Este tipo de problema tambien puede ser solucionado construyendo una red convolucional orientada a la detección o localización de rostros, o por medio de otro tipo de técnicas tradicionales basadas en la extracción de características. Debido al tiempo y bajos recursos computacionales, se opto por proponer este tipo de enfoques como trabajos futuros.



Figura 3.3: Ejemplo de rostros con oclusión.

Fuente: Face Dataset, Universidad Politécnica de Catalunya.

3.2. Experimentación en la Elección de Parámetros y Capas en la Construcción de la Arquitectura CNN

La creación de un modelo depende tanto de la arquitectura (número y orden de las capas de convolución, capas de Pooling, capas totalmente conectadas, etc.) como de los parámetros de cada capa (número de filtros en la capa de convolución, tamaño de los filtros, operaciones de agrupación en la capa de submuestreo, etc.).

¿Por qué esta configuración de capas y parámetros? Para la elección de las capas y parámetros, se hizo experimentos con distintas configuraciones en la arquitectura, seleccionando las capas y parámetros de cada una de ellas mediante prueba y error, evaluando el error y precisión de cada configuración.

Se evaluaron 3 arquitecturas con distintas configuraciones de capas y parámetros en las bases de datos FER2013 y CK+.

- **Conv-Conv-Pool-Conv-Conv-Pool-FC**

Base de Datos FER2013								
Conv	Conv	Pool	Conv	Conv	Pool	FC	Precisión	Error
64 (2x2)	64 (2x2)	2x2 (Max)	32 (4x4)	32 (4x4)	2x2 (Max)	1024x1024	45.18%	54.82%
32 (4x4)	32 (2x2)	3x3 (Avg)	32 (3x3)	64 (3x3)	3x3 (Min)	500x1024	40.72%	59.28%
16 (5x5)	32 (4x4)	4x4 (Min)	16 (2x2)	16 (2x2)	4x4 (Max)	1024x500	43.24%	56.76%
32 (4x4)	16 (4x4)	2x2 (Max)	64 (3x3)	32 (4x4)	2x2 (Avg)	1024x1024	30.1%	69.9%

Tabla 3.1: Evaluación de la arquitectura 1 y sus parámetros, FER2013

Base de Datos CK+								
Conv	Conv	Pool	Conv	Conv	Pool	FC	Precisión	Error
64 (2x2)	64 (2x2)	2x2 (Max)	32 (4x4)	32 (4x4)	2x2 (Max)	1024x1024	88.45%	11.55%
32 (4x4)	32 (2x2)	3x3 (Avg)	32 (3x3)	64 (3x3)	3x3 (Min)	500x1024	80.12%	19.88%
16 (5x5)	32 (4x4)	4x4 (Min)	16 (2x2)	16 (2x2)	4x4 (Max)	1024x500	84.24%	15.76%
32 (4x4)	16 (4x4)	2x2 (Max)	64 (3x3)	32 (4x4)	2x2 (Avg)	1024x1024	76.11%	23.89%

Tabla 3.2: Evaluación de la arquitectura 1 y sus parámetros, CK+

- **Conv-Pool-Conv-Pool-FC *Arquitectura Propuesta***

Base de Datos FER2013						
Conv	Pool	Conv	Pool	FC	Precisión	Error
64 (2x2)	2x2 (Max)	16 (4x4)	2x2 (Max)	1024x1024	39.81%	60.19%
32 (4x4)	3x3 (Avg)	32 (3x3)	3x3 (Max)	500x1024	53.78%	46.22%
16 (5x5)	4x4 (Min)	16 (2x2)	4x4 (Max)	1024x500	27.14%	72.86%
32 (4x4)	2x2 (Max)	64 (4x4)	2x2 (Max)	1024x1024	57%	43%

Tabla 3.3: Evaluación de la arquitectura 2 y sus parámetros, FER2013

Base de Datos CK+							
Conv	Pool	Conv	Pool	FC	Precisión	Error	
64 (2x2)	2x2 (Max)	16 (4x4)	2x2 (Max)	1024x1024	74.54%	25.46%	
32 (4x4)	3x3 (Avg)	32 (3x3)	3x3 (Max)	500x1024	57.86%	42.14%	
16 (5x5)	4x4 (Min)	16 (2x2)	4x4 (Max)	1024x500	74.54%	25.46%	
32 (4x4)	2x2 (Max)	64 (4x4)	2x2 (Max)	1024x1024	91%	9%	

Tabla 3.4: Evaluación de la arquitectura 2 y sus parámetros, CK+

- Conv-Pool-Pool-Conv-Conv-Pool-FC

Base de Datos FER2013								
Conv	Pool	Pool	Conv	Conv	Pool	FC	Precisión	Error
64 (2x2)	2x2 (Max)	2x2 (Max)	32 (4x4)	16 (4x4)	2x2 (Max)	2048x2048	35.17%	64.83%
64 (4x4)	3x3 (Avg)	3x3 (Avg)	64 (3x3)	32 (3x3)	2x2 (Max)	500x1024	52.18%	47.82%
32 (5x5)	4x4 (Min)	3x3 (Min)	16 (2x2)	16 (2x2)	4x4 (Max)	512x1024	30.70%	69.30%
16 (4x4)	2x2 (Max)	2x2 (Max)	64 (4x4)	64 (4x4)	3x3 (Max)	1024x1024	50.15%	49.85%

Tabla 3.5: Evaluación de la arquitectura 3 y sus parámetros, FER2013

Base de Datos CK+								
Conv	Pool	Pool	Conv	Conv	Pool	FC	Precisión	Error
64 (2x2)	2x2 (Max)	2x2 (Max)	32 (4x4)	16 (4x4)	2x2 (Max)	2048x2048	62.14%	37.86%
64 (4x4)	3x3 (Avg)	3x3 (Avg)	64 (3x3)	32 (3x3)	2x2 (Max)	500x1024	80.26%	19.74%
32 (5x5)	4x4 (Min)	3x3 (Min)	16 (2x2)	16 (2x2)	4x4 (Max)	512x1024	58.54%	41.46%
16 (4x4)	2x2 (Max)	2x2 (Max)	64 (4x4)	64 (4x4)	3x3 (Max)	1024x1024	78.12%	21.88%

Tabla 3.6: Evaluación de la arquitectura 3 y sus parámetros, CK+

3.3. Arquitectura Propuesta

La entrada de nuestra arquitectura consta de una imagen de 48x48 pixeles en escala de gris que es el resultado de la detección y recorte hecho en la fase de detección de rostro, seguido de una capa de 32 convoluciones con filtro de 4x4 sin solapamiento, luego se aplica un sub muestreo de 2x2 con función MAX⁶, seguido de una capa de 64 convoluciones con filtros de 2x2 sin solapamiento, para posteriormente aplicar un sub muestreo de 2x2 con función MAX, aplicada las convoluciones y sub muestreo procedemos a aplicar el Dropout⁷ con 20 %, seguido de dos capas de 1024 neuronas totalmente conectadas cada una. Finalmente, para la clasificación se aplica la función de normalización Softmax, que en este proyecto toma 6 clases que representan a las 6 expresiones faciales antes mencionadas.

⁶Función que determina el máximo de n números.

⁷Una forma simple de prevenir el *overfitting* en Redes Neuronales..

INPUT IMAGE 48X48 PIXELES ESCALA DE GRIS
Convolucion 32 filtros de 4x4
MaxPooling 2x2
Convolucion 64 filtros de 2x2
MaxPooling 2x2
Dropout 20%
FullConected 1024
FullConected 1024
Softmax (6 clases)

Tabla 3.7: Arquitectura del modelo propuesto

3.4. DESCRIPCIÓN DE LAS CAPAS DE LA ARQUITECTURA

La arquitectura de Red Neuronal Convolutacional sigue la siguiente composición:

- Primera capa de convolución.
- Primera capa de Pooling.
- Segunda capa de Convolución.
- Segunda capa de Pooling.
- Primera capa totalmente conectada
- Segunda capa totalmente conectada

- **Primera capa convolución.** Cuenta con 32 filtros (mapa de características) del tamaño 4x4 pixeles. Esta capa tiene la función de extraer las características relevantes (en el caso de expresiones faciales se puede ver en la Figura 26 que las características más relevantes son: los ojos, boca, nariz, y otras deformaciones en el rostro) de la imagen de entrada de tamaño 48x48 pixeles, generando 32 nuevas imágenes de tamaño 45x45 pixeles a partir de los filtros aplicados.

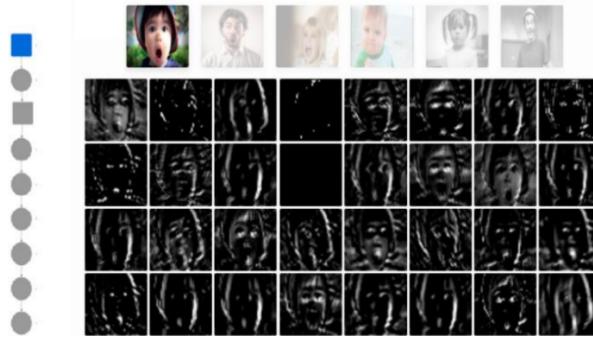


Figura 3.4: Imágenes después de la primera convolución.

Source: Propia

- **Primera capa de Pooling.** Recibe como parámetros de entrada las imágenes generadas a partir de la primera capa de convolución. Su función es la de reducir características redundantes mediante la agrupación de píxeles, generando 32 nuevas imágenes de tamaño 22x22 píxeles.

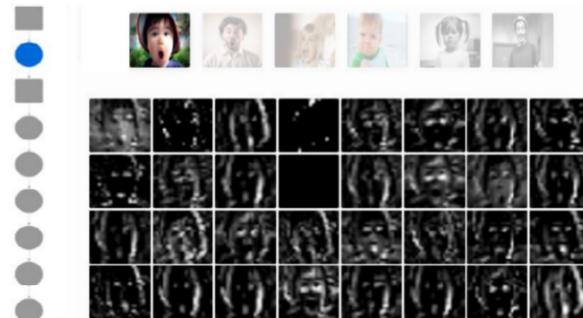


Figura 3.5: Imágenes después del primer Pooling.

Source: Propia

- **Segunda capa de Convolución.** Cuenta con 64 filtros, recibe como parámetros de entradas las imágenes generadas a partir de la primera capa de Pooling. Su función es extraer las características relevantes de las imágenes de entrada, generando 64 nuevas imágenes de tamaño 21x21 píxeles.

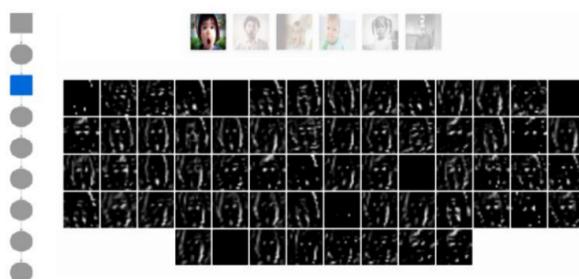


Figura 3.6: Imágenes después de la segunda convolución.

Source: Propia

- **Segunda capa de Pooling.** Recibe como parámetros de entrada las imágenes generadas a partir de la segunda capa de convolución. Su función es la de reducir características de estas imágenes mediante la agrupación de píxeles, generando 64 nuevas imágenes de tamaño 10x10 píxeles.



Figura 3.7: Imágenes después del segundo Pooling.

Source: Propia

- **Capas totalmente conectadas.** Recibe como parámetros de entrada las imágenes generadas a partir de la segunda capa de Pooling, su función es la de ajustar los pesos en las conexiones de las neuronas pertenecientes a la arquitectura, minimizando el error haciendo uso del algoritmo BackPropagation. La última capa totalmente conectada cuenta con 6 neuronas, las cuales representan las 6 expresiones faciales utilizadas en este proyecto.

3.5. PARAMETROS DE LA ARQUITECTURA

La imágenes de entrada son definidas en el tamaño de 48x48 píxeles como valor estándar basándonos en el tamaño en el cual están las imágenes de la base de datos FER2013, el número de convoluciones en la primera capa es de 32 y 64 en la segunda capa de convolución obteniendo así un total de 32x64 mapas de características, la capa de Pooling agrupa subregiones de las dimensiones 2x2 píxeles para que no se pierda mucha información, nosotros optamos por la elección de dos capas totalmente conectadas de 1024x1024 producto de los resultados obtenidos basándonos en prueba y error , el total de parámetros obtenidos con la arquitectura propuesta es de:

- Imagen de entrada: 48x48 píxeles
- 1ra capa con 32 convoluciones: 544 parámetros
- 2da capa con 64 convoluciones: 8256 parámetros
- 1ra capa totalmente conectada: 6554624 parámetros
- 2da capa totalmente conectada: 1049600 parámetros
- función de normalización Softmax: 7175 parámetros

Obteniendo un total de 7,620,199 parámetros totales.

Layer (type)	Output Shape	Param #	Connected to
convolution2d_7 (Convolution2D)	(None, 45, 45, 32)	544	convolution2d_input_4[0][0]
maxpooling2d_7 (MaxPooling2D)	(None, 22, 22, 32)	0	convolution2d_7[0][0]
convolution2d_8 (Convolution2D)	(None, 21, 21, 64)	8256	maxpooling2d_7[0][0]
maxpooling2d_8 (MaxPooling2D)	(None, 10, 10, 64)	0	convolution2d_8[0][0]
dropout_4 (Dropout)	(None, 10, 10, 64)	0	maxpooling2d_8[0][0]
flatten_4 (Flatten)	(None, 6400)	0	dropout_4[0][0]
dense_7 (Dense)	(None, 1024)	6554624	flatten_4[0][0]
dense_8 (Dense)	(None, 1024)	1049600	dense_7[0][0]
dense_9 (Dense)	(None, 7)	7175	dense_8[0][0]

Total params: 7,620,199
Trainable params: 7,620,199

Tabla 3.8: Número de parámetros de nuestra CNN

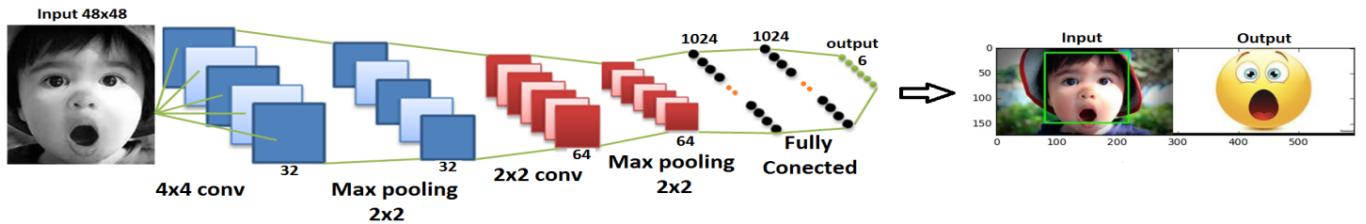


Figura 3.8: Arquitectura grafica del modelo propuesto
Source: Propio

3.6. ENTRENAMIENTO DE LA CNN

El entrenamiento de nuestra Red Neuronal Convolutacional siguió un proceso iterativo en el que se presentó como datos de entrada imágenes de expresiones faciales y sus respectivas etiquetas de salida (clases correspondientes a la expresión facial a la cual pertenece: enojo, miedo, alegría, tristeza, sorpresa y neutro).

Durante esta fase de entrenamiento, la Red Neuronal Convolutacional aprendió mediante el ajuste de sus pesos, con el fin de ser capaz de predecir la etiqueta de clase correcta de los datos de entrada, el algoritmo de Red Neuronal más popular para la fase de entrenamiento es el algoritmo de BackPropagation, dicho algoritmo se usó en nuestra fase de entrenamiento. Los pesos iniciales de nuestra red se eligieron al azar y comienza el entrenamiento o aprendizaje. Se procesó los datos de entrada para lograr obtener las etiquetas deseadas obteniendo un error el cual se propagó hacia atrás mediante el algoritmo antes mencionado(BackPropagation) haciendo que se ajusten los pesos, este proceso ocurrió una y otra vez hasta que se minimizó el error y eso ocurrió cuando se logró una convergencia de los datos.

3.7. TEST AL MODELO CREADO

Una vez creada el modelo (un archivo con extensión .h5) se procede a realizar las consultas a dicho modelo, estas consultas siguen los siguientes pasos:

- Leer una imagen de entrada, de dimensiones mayos o igual a 48x48 pixeles.
- Utilizar Haar Cascade para la detección del rostro en la imagen antes ingresado.
- Extraer el rostro detectado y redimensionarlo al tamaño 48x48 pixeles.
- Dar como imagen de entrada la imagen obtenida en el paso anterior.

Después de realizar los pasos anteriores, el modelo arrojara un valor asociado a la expresión facial predicha.

3.8. RECOPILACIÓN DE IMAGENES DE EXPRESIONES FACIALES

La recopilación de las imágenes de expresiones faciales se obtuvo de 2 fuentes secundarias de información (internet) en los cuales los datos están pre-elaborados (imágenes con tamaños de 48x48 pixeles de base de datos FER20131 y 640x490 o 640x480 píxeles de la base de datos CK+).

3.9. BASE DE DATOS

Se usó 3 bases de datos (*FER2013*¹ y *CK+*²) y una tercera como resultado de la unión de las 2 bases de datos antes mencionadas.

3.9.1. FER2013

Es una base de datos del sitio web Kaggle1 para el concurso de reconocimiento de expresiones faciales.

Esta base de datos posee 35887 imágenes en escala de gris de 48x48 pixeles, clasificados en 7 categorías (enojado, disgustado, miedo, feliz, triste, sorpresa y neutro). En este trabajo se optó por unir la categoría enojado y disgustado por las similitudes que tienen entre ellas.

Separamos la data en 2 partes training y test. El training consta de 32298 imágenes y el test de 3589 imágenes.



Figura 3.9: Imágenes de la base de datos FER2013
Source: Kaggle

3.10. CK+

La base de datos *CK+²* (Cohn-Kanade) posee imágenes de expresiones faciales frontales de 210 personas en resolución de 640x490 o 640x480 pixeles. Nosotros elegimos de entre ellos 3289 imágenes convirtiéndolos a escala de gris de 48x48 pixeles y clasificándolos en 6 categorías (enojado, miedo, feliz, triste, sorprendido y neutro). Nuestro training consta de 2966 imágenes y el test de 323 imágenes.



Figura 3.10: Imágenes de la base de datos CK+
Source: Base de datos CK+

3.11. FER2013 - CK+

Esta base de datos resulta de la unión de la base de datos Fer2013 y CK+, obteniendo un total de 39176 imágenes de 48x48 en escala de gris. El training tiene 35264 y el test 3912 imágenes.

3.12. RESULTADOS EXPERIMENTALES

A continuación, se muestra los resultados que se obtuvieron en las diferentes bases de datos FER2013, CK+ y la tercera base de datos que se obtuvo como resultado de la unión de los dos anteriores mencionadas.

Se podrá apreciar los niveles de precisión alcanzado por cada categoría – Expresión Facial (Enojado, Miedo, Feliz, Triste, Sorprendido, Neutro). Así como sus matrices de confusión que nos mostrarán los resultados positivos y sus falsos positivos, pudiendo así interpretar de mejor manera los resultados.

3.12.1. FER2013

	precision	recall	f1-score	support
Enojado	0.46	0.58	0.51	546
Miedo	0.52	0.36	0.43	528
Feliz	0.74	0.75	0.75	879
Triste	0.43	0.40	0.41	594
Sorprendido	0.71	0.77	0.74	416
Neutro	0.52	0.54	0.53	626
avg / total	0.57	0.57	0.57	3589

Tabla 3.9: Resultados obtenidos - FER2013

En la Tabla 3 se puede apreciar los niveles de precisión en la clasificación de los datos de la base de datos FER2013, mostrando en la categoría Enojado 46 %, Miedo 52 %, Feliz 74 % Triste 43 %, Sorprendido 71 % y Neutro 52 %.

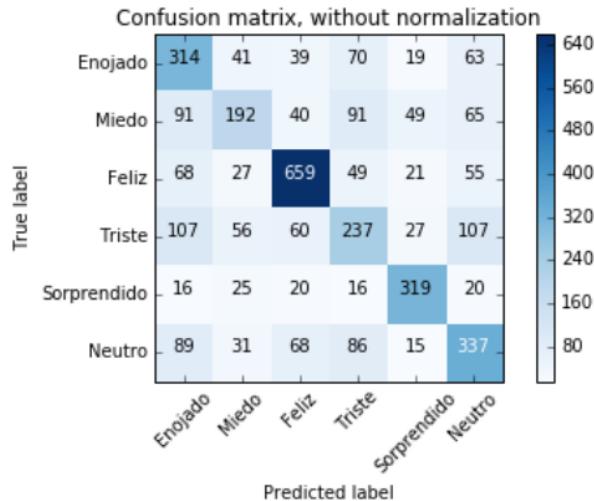


Figura 3.11: Matriz de confusión, precisión del Test - FER2013

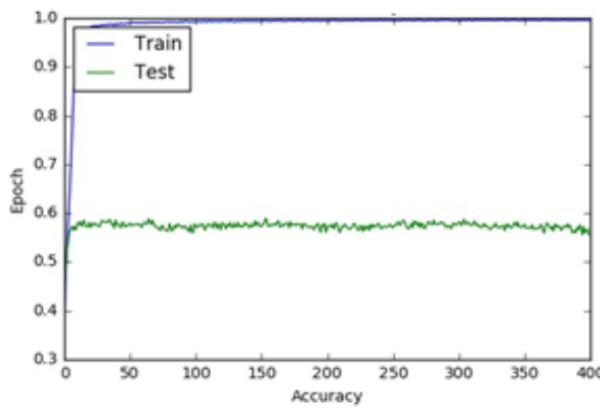


Figura 3.12: Precisión durante el proceso de entrenamiento y prueba (%) – FER2013

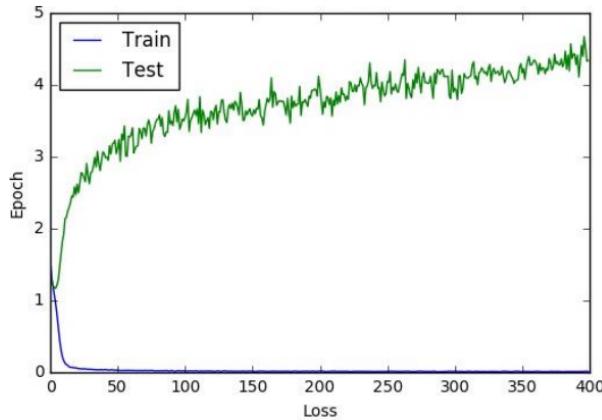


Figura 3.13: Perdida durante el proceso de entrenamiento y prueba (%) – FER2013

3.12.2. CK+

	precision	recall	f1-score	support
Enojado	0.91	0.76	0.83	66
Miedo	0.76	1.00	0.86	25
Feliz	1.00	0.99	0.99	83
Triste	0.87	1.00	0.93	48
Sorprendido	1.00	0.90	0.95	58
Neutro	0.78	0.84	0.81	43
avg / total	0.91	0.91	0.91	323

Tabla 3.10: Resultados obtenidos - CK+

En la Tabla 4 se puede apreciar los niveles de precisión en la clasificación de los datos de la base de datos CK+, mostrando en la categoría Enojado 91 %, Miedo 76 %, Feliz 100 %, Triste 87 %, Sorprendido 100 % y Neutro 78 %.

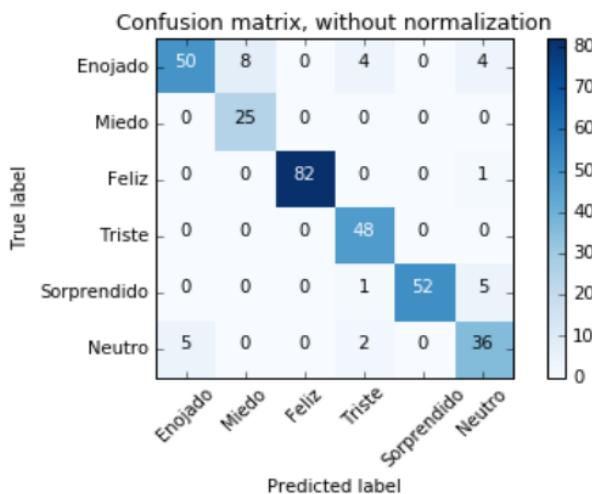


Figura 3.14: Matriz de confusión, precisión del Test - CK+

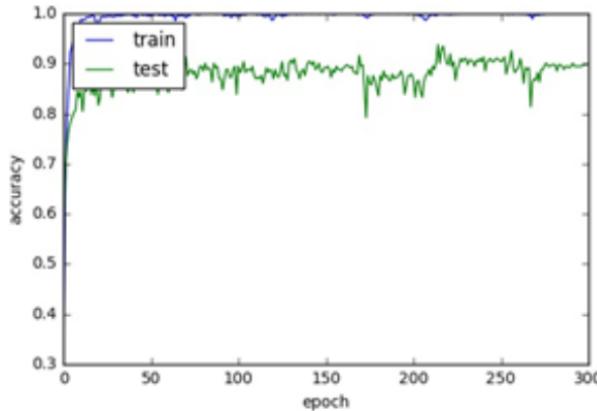


Figura 3.15: Precisión durante el proceso de entrenamiento y prueba (%) - CK+

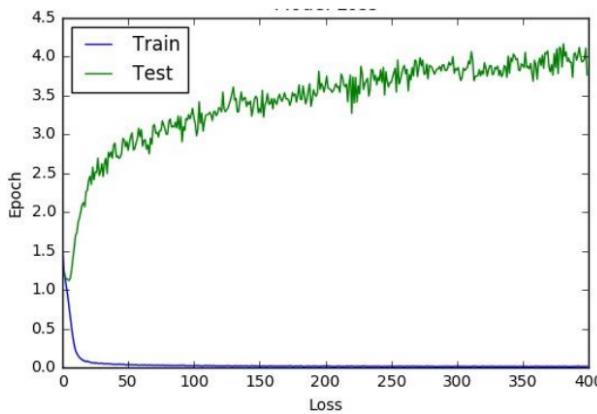


Figura 3.16: Perdida durante el proceso de entrenamiento y prueba (%) – FER2013

3.12.3. FER2013 - CK+

	precision	recall	f1-score	support
Enojado	0.57	0.50	0.53	612
Miedo	0.48	0.46	0.47	553
Feliz	0.75	0.79	0.77	962
Triste	0.44	0.48	0.46	642
Sorprendido	0.77	0.72	0.74	474
Neutro	0.53	0.55	0.54	669
avg / total	0.60	0.60	0.60	3912

Tabla 3.11: Resultados obtenidos - FER2013 - CK+

En la Tabla 5 se puede apreciar los niveles de precisión en la clasificación de los datos de la base de datos (FER2013 - CK+), mostrando en la categoría Enojado 57 %, Miedo 48 %, Feliz 75 %, Triste 44 %, Sorprendido 77 % y Neutro 53 %

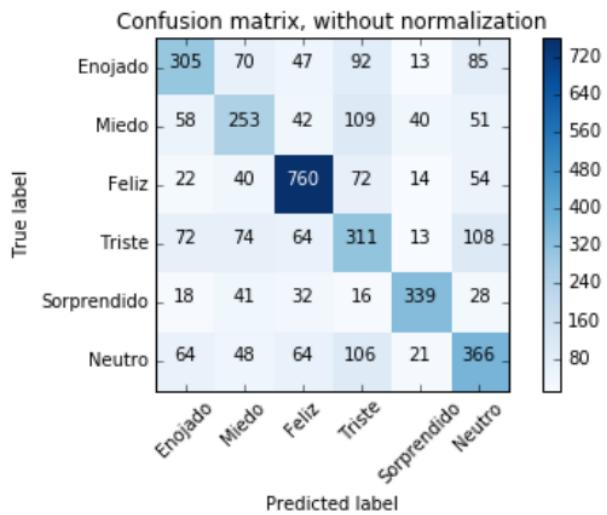


Figura 3.17: Matriz de confusión, precisión del Test FER2013 - CK+

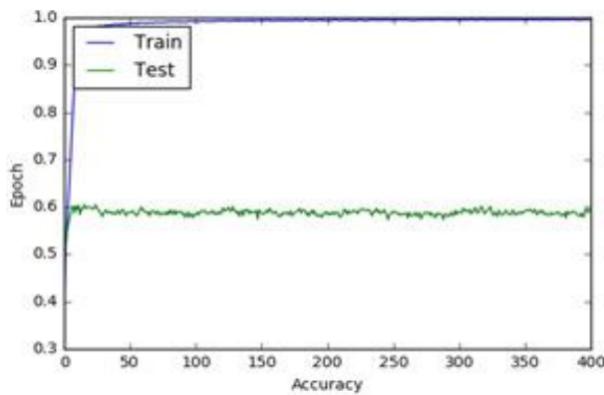


Figura 3.18: Precisión durante el proceso de entrenamiento y prueba (%) FER2013 - CK+

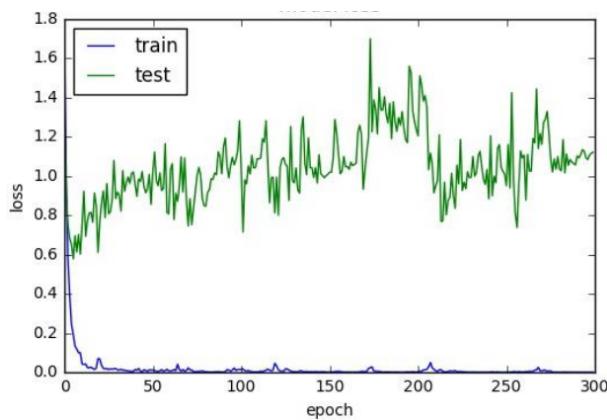


Figura 3.19: Perdida durante el proceso de entrenamiento y prueba (%) FER2013 - CK+

RESULTADOS GENERALES

Se obtuvo un nivel de precisión de 91% con la base de datos CK+ (Tabla 4), 57% con FER2013 (Tabla 3) y 60% con la unión de ambas bases de datos (Tabla 5), Estando 14% debajo del nivel de precisión del primer lugar del concurso mundial de reconocimiento de expresiones faciales – Kaggle 1 debido a las limitaciones de Hardware que se presentaron en el desarrollo de este trabajo (uso de CPU más no de GPU en la fase de entrenamiento).

CONCLUSIONES

- El desarrollo de una arquitectura de Red Neuronal Convolucional es muy compleja, debido a que no se cuenta con fundamentos teóricos para la correcta selección de parámetros (filtro de convolución, submuestreo, neuronas, etc.). La arquitectura propuesta muestra resultados con niveles de precisión alto, lo cual da evidencia que se hizo una correcta selección de las capas y los parámetros que lo componen.
- Existen dos formas de recopilación de datos: La primera consiste en crear una propia base de datos lo cual requiere de tiempo y dinero, la segunda opción y por la que se optó en este proyecto, consiste en extraer datos de internet de organizaciones dedicadas al campo de estudio.
- El uso de 2 capas de convolución con 64 y 32 filtros de tamaños 4x4 y 2x2 pixeles respectivamente muestra que es una buena selección de parámetros para la extracción de características de expresiones faciales.
- El Submuestreo o Pooling cumple funciones importantes relacionadas con el coste computacional, reduciendo el número de operaciones de computo con la disminución de las dimensiones de la imagen con el fin de reducir características. La utilización de 2 capas de Submuestreo de tamaño de agrupación 2x2 pixeles y con función Max, muestra que es una buena selección de parámetros para la reducción de características.
- La función de activación RELU resulta ser la mejor opción para la implementación de una arquitectura de Red Neuronal por los resultados mostrados en el estado del arte del Deep Learning.
- La función de normalización softmax es muy eficiente para la clasificación de múltiples clases por los resultados mostrados en el estado del arte del Deep Learning.
- Se entrenó satisfactoriamente la Red Neuronal Convolutinal (basándonos en la técnica early stopping - Ver anexos), construida a partir de las capas antes mencionadas, teniendo algunas limitaciones, sea el caso de recursos computacionales, ocasionando demoras para la fase de entrenamiento, ya que solo se contó con el uso de CPU mas no de GPU.
- En la base de datos de datos CK+ se obtuvo un nivel de precisión alto por que las imágenes muestran rasgos resaltantes de las expresiones faciales los cuales fueron etiquetados manualmente en esta investigación. En FER2013 se muestra un nivel de precisión no

muy bueno (Tabla 2) por el desbalance de datos en algunas categorías y para nivelarlos y alcanzar mejores resultados (Tabla 4), una opción es combinar con otras bases de datos, pero se corre riesgo de que los criterios de etiquetado de las expresiones faciales difieran.

RECOMENDACIONES

Por la experiencia en la realización el presento proyecto de investigación, se recomienda:

- Desarrollar la fase de entrenamiento con una CPU con capacidad mínima de 8GB de RAM, y en caso se cuente con la posibilidad de obtener una GPU, como mínimo esta debe tener 4GB.
- Acceder a material de investigación (papers. artículos científicos y otros) de instituciones prestigiosas como la IEEE, ACM, SPRINGER y otros.
- Usar Python como lenguaje de programación por las facilidades que brinda y por el uso concurrido a nivel mundial.
- Asistir a congresos de Machine Learning y Pattern Recognition para poder resolver dudas existentes directamente con expertos en esta área de investigación.

TRABAJOS FUTUROS

A futuro se tiene pendiente el reconocimiento de expresiones faciales en tiempo real, reemplazando el detector de rostros Haar Casacade por uno basado en Deep Learning y para nivelar el desbalance de datos por categoría se tiene pensado utilizar data augmentation.

BIBLIOGRAFIA

- [1] M. Alonso, A. Díaz, M. Alonso, and A. Aguado. *Personas con discapacidad: perspectivas psicopedagógicas y rehabilitadoras.* Manuales (Siglo XXI de España Editores).: Psicología. Siglo XXI de España, 2005.
- [2] Y. Bengio, A. Courville, and P. Vincent. Representation learning: A review and new perspectives. *IEEE transactions on pattern analysis and machine intelligence*, 35(8):1798–1828, 2013.
- [3] D. Ciregan, U. Meier, and J. Schmidhuber. Multi-column deep neural networks for image classification. In *Computer Vision and Pattern Recognition (CVPR), 2012 IEEE Conference on*, pages 3642–3649. IEEE, 2012.
- [4] C. Clark and A. Storkey. Training deep convolutional neural networks to play go. In *International Conference on Machine Learning*, pages 1766–1774, 2015.
- [5] CS231n. Convolutional Neural Network for Visual Recognition. <http://cs231n.github.io/convolutional-networks/#norm>, 2016. Last access: 2016-07-13.
- [6] deeplearning4j. Early Stopping. <https://deeplearning4j.org/earlystopping#early-stopping>, 2016. Last access: 2016-10-30.
- [7] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. Imagenet: A large-scale hierarchical image database. In *Computer Vision and Pattern Recognition, 2009. CVPR 2009. IEEE Conference on*, pages 248–255. IEEE, 2009.
- [8] P. Ekman. What scientists who study emotion agree about. *Perspectives on Psychological Science*, 11(1):31–34, 2016.
- [9] L. Fei-Fei, R. Fergus, and P. Perona. Learning generative visual models from few training examples: An incremental bayesian approach tested on 101 object categories. *Computer vision and Image understanding*, 106(1):59–70, 2007.
- [10] G. Griffin, A. Holub, and P. Perona. Caltech-256 object category dataset. 2007.
- [11] S. Houben, J. Stallkamp, J. Salmen, M. Schlipsing, and C. Igel. Detection of traffic signs in real-world images: The german traffic sign detection benchmark. In *Neural Networks (IJCNN), The 2013 International Joint Conference on*, pages 1–8. IEEE, 2013.
- [12] Intelygenz. Machine Learning and application. <http://www.intelygenz.es/que-es-machine-learning-y-que-aplicaciones-tiene-dia-a-dia/>, 2016. Last access: 2016-10-27.

- [13] José Rosales Fernández. Redes Neuronales. <http://www.usmp.edu.pe/publicaciones/boletin/fia/info32/pag4.htm>, 2016. Last access: 2016-09-11.
- [14] A. Krizhevsky, I. Sutskever, and G. E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pages 1097–1105, 2012.
- [15] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [16] B. W. M. A. Lehr. Backpropagation and its applications. In *Neural Network Computing for the Electric Power Industry: Proceedings of the 1992 INNS Summer Workshop*, page 21. Psychology Press, 1993.
- [17] R. Padilla, C. Costa Filho, and M. Costa. Evaluation of haar cascade classifiers designed for face detection. *World Academy of Science, Engineering and Technology*, 64, 2012.
- [18] P. D. Pusiol. Redes convolucionales en comprensión de escenas. B.S. thesis, 2014.
- [19] G. J. P. Restrepo Arteaga et al. Aplicación del aprendizaje profundo (deep learning) al procesamiento de señales digitales. B.S. thesis, Universidad Autónoma de Occidente, 2015.
- [20] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, et al. Imagenet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3):211–252, 2015.
- [21] C. Sabino. Como hacer una tesis y elaborar todo tipo de escritos. *Editorial Panapo. Venezuela*, 1994.
- [22] P. Sermanet and Y. LeCun. Traffic sign recognition with multi-scale convolutional networks. In *Neural Networks (IJCNN), The 2011 International Joint Conference on*, pages 2809–2813. IEEE, 2011.
- [23] E. L. d. Silva and E. M. Menezes. Metodología da pesquisa e elaboração de dissertação. 2001.
- [24] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel. Man vs. computer: Benchmarking machine learning algorithms for traffic sign recognition. *Neural networks*, 32:323–332, 2012.
- [25] L. E. Sucar and G. Gómez. Visión computacional. *Instituto Nacional de Astrofísica, Óptica y Electrónica. México*, 2011.
- [26] Wikipedia. Autoencoder. <https://en.wikipedia.org/wiki/Autoencoder>, 2016. Last access: 2016-10-22.
- [27] Wikipedia. Confusion Matrix. https://en.wikipedia.org/wiki/Confusion_matrix, 2016. Last access: 2016-10-26.

- [28] Wikipedia. Función de activación Relu. [https://en.wikipedia.org/wiki/Rectifier_\(neural_networks\)](https://en.wikipedia.org/wiki/Rectifier_(neural_networks)), 2016. Last access: 2016-10-20.
- [29] Wikipedia. Función de activación Sigmoide. https://es.wikipedia.org/wiki/Funci%C3%B3n_sigmoide, 2016. Last access: 2016-10-20.
- [30] Wikipedia. Función de activación tangencial. https://es.wikipedia.org/wiki/Tangente_hiperb%C3%ADlica, 2016. Last access: 2016-10-20.
- [31] Wikipedia. Visión por computador. https://es.wikipedia.org/wiki/Visi%C3%B3n_artificial#cite_note-1, 2016. Last access: 2016-08-01.
- [32] Y. LeCun, C. Cortes, y C. Burges. Mnist: A dataset of handwritten digits. <http://yann.lecun.com/exdb/mnist/>, 2014. Last access: 2016-10-01.

Apéndice A

OTROS CONCEPTOS

pendiente.

Apéndice B

TESTING

pendiente.

Apéndice C

HERRAMIENTAS

pendiente.

Apéndice D

GLOSARIO

pendiente.

Apéndice E

ACRONIMOS

pendiente.